

ZÁKLADY OPTIMALIZÁCIE

(ZU)

(1x)

(1) Definícia 1:

- $f(x)$ sa nazýva cieľová (cielová, objektívna) funkcia
- M sa nazýva m�ina prípustných riešení
- Body $x \in M$ sa nazývajú prípustnými riešeniami
- Aké $x^0 \in M$, pre ktoré platí $f(x^0) \leq f(x), \forall x \in M$ sa nazýva optimálnym riešením

Poznámka:

$$\text{Platí: } \max_{\mathbb{R}^n} f(x) = -\min_{\mathbb{R}^n} -f(x)$$

$$\text{Niekedy je uloha } \sup_M (\inf_M) f(x)$$

(2) Definícia:

Uloha LP v normálnom tvare nazývame uloha

$$\max_{\mathbb{R}^n} C^T x, M = \{x \in \mathbb{R}^n \mid Ax \leq b, x \geq 0\}, A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m, C \in \mathbb{R}^n$$

Konvexné programovanie

$\min_{\mathbb{R}^n} f(x)$, $f(x)$ je funkcia g_j o pojmom M t.j. $M = \{x \in \mathbb{R}^n \mid g_j(x) \leq 0, j=1, \dots, m\}$

je konvekné. Robia sennu ulohu $\max_{\mathbb{R}^n} f(x)$, kde $f(x)$ je $g(x)$ je konkávne,

$$M \in \{x \in \mathbb{R}^n \mid g_j(x) \geq 0, j=1, \dots, m\}.$$

gradientné metódy = metódy prímeriach smerov

Cieľové programovanie

$$\text{Uloha LP: } \min_{\mathbb{R}^n} C^T x, M_C = \{x \in \mathbb{R}^n \mid Ax = b, x \geq 0, x_j \in \mathbb{Z}, j \in \{1, \dots, n\}\}$$

Optimizačné procesy

- spojité rozhodovacie problém

Semiinfinitné programovanie

$$\max_{\mathbb{R}^n} C^T x, M = \{x \in \mathbb{R}^n \mid a(t) \leq b(t)\} \text{ kde pre každom } t \in T \subset \mathbb{R}^m \text{ je} \\ a(t) \in \mathbb{R}^n, b(t) \in \mathbb{R}, C \in \mathbb{R}^n, T \text{ je kompaktná a konvexná}$$

Cieľová semiinfinitná uloha

(3) Výhodstva simplexového algoritmu

E	A _N	b
0 ... 0	C _N - Z _N	-C ₀

$$\text{keď } Z_N = C^T A_N$$

Tabuľka s k-kom krokmi: (predpokladame, že E je na posledných miestach)

D	E	d_0
$c_N - z_N$	$b - \dots$	0

(9) Dostávame ju v e-motifikovanéj forme:

Ak máme jednoznačne určený aktuálny reťazec, tak súvisí náznačky s posledovnosťou pravkov prvého stĺpca tabuľky sú pravkami aktuálneho stĺpca, ktoré padajú do miest ako pravoly. Máme tu ale, že niektorí sú z možných kandidátov na pravola výberieme. Potom berieme do miesty druhý stĺpec tabuľky, potom tretí a tak ďalej. Vzhľadom k tomu, že v tabuľke existuje jednoznačná matice, tak máme ju po končnom počte krokov najť pravola jednoznačne.

Potom vypočítame transformáciu tabuľky.

(10)

Veta:

ak sú $\mathbf{x}^1, \mathbf{x}^2$ dve optimálne riešenia úlohy LP, potom existujú hodnoty reálov $\lambda(\mathbf{x}^1, \mathbf{x}^2) = \{ \lambda \in \mathbb{R}^n \mid \mathbf{x} = \lambda_1 \mathbf{x}^1 + \lambda_2 \mathbf{x}^2, \lambda_1 + \lambda_2 = 1, \lambda_1, \lambda_2 \geq 0 \}$, ťaž sú optimálnym riešením úlohy LP.

Dôkaz:

Dôkaz: $C^T \mathbf{x}^1 = C^T \mathbf{x}^2 = C_0$, platí pre každú $\mathbf{x} \in U(\mathbf{x}^1, \mathbf{x}^2)$:

$$C^T \mathbf{x} = C^T (\lambda_1 \mathbf{x}^1 + \lambda_2 \mathbf{x}^2) = \lambda_1 C^T \mathbf{x}^1 + \lambda_2 C^T \mathbf{x}^2 = (\lambda_1 + \lambda_2) C_0 = C_0$$

Tvrdenie:

M_{opt} je ravnaké súčinom steny M miestnej dimenze.

Bez jásazu (viličnosť)

Príklad: ✓ Veta 1: ...

$$\begin{aligned} M &= \{ \mathbf{x} \in \mathbb{R}^4 \mid x_1 - 2x_2 + 3x_3 - x_4 = 5, \\ &\quad -2x_1 + x_2 + x_3 + 2x_4 = 2, \\ &\quad x_1, \dots, x_4 \geq 0 \} \end{aligned}$$

$$M_{opt} = \{ \mathbf{x} \in \mathbb{R}^4 \mid$$

$$\begin{aligned} &-2x_1 + 3x_3 - x_4 = 5, \\ &x_2 + x_3 + 2x_4 = 2, \\ &x_1 = 0, x_2, x_3, x_4 \geq 0 \} \end{aligned}$$

20 2x

Dosledok:

ak všetky $c_j - z_j > 0 \quad (j \in N)$, potom \mathbf{x}^0 je jediným optimálnym riešením

Poznámka:

ak v poslednej (optimálnej) tabuľke nájdeme nejake $c_j - z_j = 0 \quad j \in N$, potom stálemo musíme rovolať príslušný (j -ty) odberať zo slídkov.

1) ak nájdeme pivot (\exists spočiť jedna hodnota v d_i^*), vracame ho $d_{r,j} > 0$, potom nové prípravné lišické riešenie má hodnotu celovej funkcie

$$-c_0' = -c_0 - \frac{(c_j - z_j) d_{r,j}}{d_{r,j}} = -c_0, \text{ keď optimálna hodnota celovej funkcie}$$

funkcie ostala rovnaká a dostali sme nové optimálne riešenie.

2) ak pivot $d_{r,j} \leq 0$ (nieexistuje pivot), potom sú iba tri

$h = \{ \mathbf{x} \in \mathbb{R}^n \mid \mathbf{x} = \mathbf{x}^0 - d_{r,j} x_j, x_j \geq 0 \}$
príslušné optimálne riešenie sú $x_k = 0, k \in N \setminus j$.

Z prípravných riešení $\Rightarrow \mathbf{x}_B = \mathbf{d}^0 - D \mathbf{x}_N$
 $\mathbf{x}_N = \mathbf{0} - (-\mathbf{x}_N) \quad \text{pre } \forall \mathbf{x} \in M$.

ak položime $x_k, k \in N \setminus j \Rightarrow \mathbf{x}_B = \mathbf{d}^0 - D x_j \geq 0$
 $\mathbf{x}_N = \mathbf{0} - (-\mathbf{0})$

Pre $\mathbf{x} \in h$: $\mathbf{c}^T \mathbf{x} = c_0 + \sum_{k \in N} (c_k - z_k) x_k = c_0 + \underbrace{(c_j - z_j)}_{=0} x_j = c_0$
 $\text{alebo } x_k = 0, k \in N \setminus j$

Kombináciou riešení týchto optimálnych riešení nájdeme celú M^0 , alebo ťaž čas.

(12)

REVÍZOVANÁ SM - rešteva sa E (základovou maticou)

(10.)

\mathbf{y}	
\mathbf{x}^1	\mathbf{x}^2
A	B
$-c$	0

$$(P) \max_{M_1} \mathbf{c}^T \mathbf{x}, \quad M_1 = \{ (\mathbf{x}_1, \mathbf{x}^2) \in \mathbb{R}^{n+m} \mid A \mathbf{x}_1 + \mathbf{x}^2 = \mathbf{b}, \mathbf{x}_1, \mathbf{x}^2 \geq 0 \}$$

$$(D) \min_{M_2} \mathbf{b}^T \mathbf{y}, \quad M_2 = \{ (\mathbf{y}_1, \mathbf{y}^2) \in \mathbb{R}^{m+n} \mid A^T \mathbf{y}_1 - \mathbf{y}^2 = \mathbf{c}, \mathbf{y}_1, \mathbf{y}^2 \geq 0 \}$$

(11) $y^0 \rightsquigarrow x^0$

ak y^0 je opt. riešením (D) ačo $J_2 = \{i \in \{1, \dots, m\} \mid y_i^0 > 0\}$, $J_2 = \{j \in \{1, \dots, n\} \mid a_j^T y^0 > c_j\}$,
 Potom $M_2^{\text{opt}} = \{x^0 \in M_1 \mid a_i x^0 = b_i, i \in J_2, i x_j^0, j \in J_2\}$.

Poznámky:

Kvadratickej vlohe LP $\max_{M_1^*} c^T x$, $M_1^* = \{x \mid a_i^T x = b_i, i \in J_1, x_j \geq 0, j \in J_2\}$
 $a_i^T x \geq b_i, i \in J_2, x_j \in \mathbb{R}, j \in J_2$
 $a_i^T x = b_i, i \in J_3$ benešmedom, čiže rovnice

$$\begin{cases} a_i^T x \leq -b_i, i \in J_2 \\ a_i^T x \leq b_i, i \in J_3 \end{cases} \quad a_i^T x \leq b_i, i \in J_2 \cup J_3$$

je dualna vloha $\min_{M_2^*} \left\{ \sum_{i \in J_2} b_i y_i + \sum_{i \in J_3} b_i y_i \right\}$, $M_2^* = \{y \mid a_j^T y = c_j, j \in J_2, y_j \in \mathbb{R}, j \in J_1, a_j^T y \geq c_j, j \in J_1, y_j \geq 0, j \in J_2 \cup J_3\}$

(12)

Mýšlenka dualnej SM: Vlohy (P) a (D) sú rovnako riešené. Postupuje sa po dvojicach
 korektných riešení oboch vloch s rovnakými hodnotami celobodových funkcií.


(13)

Cviček $\lambda_{00}^* = \lambda_{00}$ nazvané iba v prípade degenerátívneho prípadu korektného
 riešenia (D'), t.j. $\bar{T}_{00} = 0$ pre nejaké r. Čiže menoval cyklus (tedy by DSM
 zlyhal), ak sa postupovali 2 spôsobmi:

1.) Blondore pravidlo: každý index hľadaného stepu sa berie

$$r^* = \min \{r \mid \frac{\bar{T}_{0r}}{|\bar{J}_{0r}|} = \min_{\substack{J \in \mathbb{N} \\ |\bar{J}_{0J}| \leq 0}} \frac{\bar{T}_{0J}}{|\bar{J}_{0J}|}\}$$

2.) ϵ -modifikácia (nenosíce ani degenerácia)



$$y^* = -c + E \epsilon^1 - A^T \epsilon^2, \text{ kde } \epsilon^1 = (\epsilon^1, \epsilon^2, \dots, \epsilon^n) \\ \epsilon^2 = (\epsilon^{n+1}, \dots, \epsilon^{nm})$$

kde $\epsilon > 0$ je tubovotné meno
 $\Rightarrow y^* > 0$

Príklad:

$$(P) \max_{M_1} \{-x_1 - 2x_3\}$$

$$M_1 = \{x \in \mathbb{R}^3 \mid \begin{aligned} -x_1 + 2x_2 - x_3 &\leq -4 \\ 2x_1 + x_2 - 2x_3 &\leq -1 \\ x_1, x_2, x_3 &\geq 0 \end{aligned}\}$$

$$(D) \min_{M_2} \{-4y_1 - 2y_2\}$$

$$M_2 = \{y \in \mathbb{R}^2 \mid \begin{aligned} -y_1 + 2y_2 &\geq -1 \\ 2y_1 + y_2 &\geq 0 \\ -y_1 - 2y_2 &\geq -2 \\ y_1, y_2 &\geq 0 \end{aligned}\}$$

20 3x

ekvivalentné riešenia:

$$(P') \max_{M_1^1} \{-x_1 - 2x_3\}$$

$$M_1^1 = \{ \mathbf{x}_1, \mathbf{x}_1' \mid \begin{aligned} -x_1 + 2x_2 - x_3 + x_4 &= -4 \\ 2x_1 + x_2 - 2x_3 &+ x_5 = -2 \\ x_1, \dots, x_5 &\geq 0 \end{aligned}\}$$

$$(D') \min_{M_2^1} \{-4y_1 - 2y_2\}$$

$$M_2^1 = \{ \mathbf{y}_1, \mathbf{y}_1' \mid \begin{aligned} -y_1 + 2y_2 - y_3 &= -1 \\ 2y_1 + y_2 - y_4 &= 0 \\ -y_1 - 2y_2 &- y_5 = -2 \\ y_1, \dots, y_5 &\geq 0 \end{aligned}\}$$

Výkrodejne řešenia:

$$\begin{array}{c|ccc|c} & y_3 & y_4 & y_5 & b \\ \hline y_1 & x_4 & \textcircled{1} & 2 & -1 & -4 \\ y_2 & x_5 & 2 & 1 & -2 & -2 \\ \hline -C & 1 & 0 & 2 & 0 & 0 \end{array} \quad r$$

Výkrodejne riešenia pre (D') :

$$\begin{cases} y_1 = 0, y_2 = 0 \\ y_3 = 1, y_4 = 0, y_5 = 2 \end{cases}$$

Výkrodejne řešenia pre (P') :

$$\begin{cases} x_1 = 0, x_2 = 0, x_3 = 0 \\ x_4 = -4, x_5 = -2 \end{cases}$$

Hodnota celkových funkcií = 0.

$$s = 1$$

$$r = \min_{\text{index}} \left\{ \frac{1}{|-1|}, \frac{2}{|-1|} \right\} = 1 \quad \left\{ \begin{array}{l} \text{pivot } d_{sr} = d_{11} = -1 \\ \uparrow \quad \uparrow \\ 1 \quad 2 \end{array} \right\} \Rightarrow$$

pivot $d_{sr} = d_{11} = -1$

Do transformácie:

$$\begin{array}{c|ccc|c} & y_3 & y_4 & y_5 & b \\ \hline y_1 & x_1 & -1 & -2 & 1 & 4 \\ y_2 & x_5 & 2 & 5 & \textcircled{-4} & -10 \\ \hline -C & 1 & 2 & 1 & -4 & \end{array} \quad r$$

(25) Definícia:

Ober hľadateľnosť riešení (2) na maximu minima

$$\mathcal{L} = \{\lambda \in \mathbb{R} \mid \text{riešenie}(2) \in \text{minima}\}$$

Definícia:

Ak pre nekeď $\lambda_1 \in \mathbb{R}$ existuje optimálne riešenie riešení (2) \mathbf{x}_1 , potom interval

$$I_1 = \{\lambda \in \mathbb{R} \mid \min (\mathbf{C} + \lambda \mathbf{C}')^\top \mathbf{x} = (\mathbf{C} + \lambda \mathbf{C}')^\top \mathbf{x}_1\} = [\underline{\lambda}_1, \bar{\lambda}_1]$$

je nazývaný obor stability riešenia \mathbf{x}_1 .

Definícia:

Funkcia $\Psi(\lambda) = \min_M (\mathbf{c} + \lambda \mathbf{c}')^T \mathbf{x}$; $\lambda \in \mathbb{R}$ sa nazýva funkcia stabilitu vlohy (2).

riesiteľnosť

Poznámka:

Ak je zadaný interval I pre parameter λ , možno sa nájsť kľúča

$$\min_{M \times I} (\mathbf{c} + \lambda \mathbf{c}')^T \mathbf{x}$$

(27) 2. vydanie

Dôkaz 3V LPP:

x_B	x_N	x_r	$d_{sr} > 0$
x_S		$\downarrow > 0$	
x_B	E	D	$d_r > 0$
	$(\mu + \bar{\lambda}_1)$		$= 0$

Z poslednej tabuľky SM, ktorá vrátila optimálne riešenie x_1 :

$$\bar{\lambda}_1 = \inf_{J_2} \left\{ -\frac{\mu_j}{v_j} \right\} = \min_{v_j < 0} \left\{ -\frac{\mu_j}{v_j} \right\} = -\frac{\mu_r}{v_r}$$

$$J_2 = \{j \in N \mid v_j < 0\}$$

a pre $\lambda \in (\underline{\lambda}_1, \bar{\lambda}_1)$ je x_1 optimálne, pričom $\mu + \bar{\lambda}_1 v_r \geq 0$ a tiež platí

$\mu_r + \bar{\lambda}_1 v_r = 0$ (zložené rovnosť). Tiež 2 možnosti:

1.) $d_r \leq 0$. $\exists 2V SM \Rightarrow$ pre také λ , pre ktoré $\mu_r + \bar{\lambda}_1 v_r < 0$, neplatí riešenie vlohy (2). $v_r < 0 \Rightarrow \lambda > -\frac{\mu_r}{v_r} = \bar{\lambda}_1$ a pre $\lambda > \bar{\lambda}_1$ neplatí riešenie.

2.) $d_r \neq 0 \Rightarrow \exists$ kľúčový pravoh stĺpca v tabuľke. Tento sa v kľúčovom stĺpco v kľúčovom riadku je na jeho vrcholu x_1 . Vykona sa 1 krok SM a rieška $x_2 \rightarrow$ nasledujúci vrchol vrcholu x_1 . Podľa 1. LPP ($\bar{\lambda}_1$ alebo x_1 a x_2 alebo x_1) \exists neprerryvý interval $(\underline{\lambda}_2, \bar{\lambda}_2)$ taký, že

- $\forall \lambda \in (\underline{\lambda}_2, \bar{\lambda}_2)$ je x_2 optimálnym riešením,
- $(\underline{\lambda}_2, \bar{\lambda}_2)$ je najväčší interval s touto vlastnosťou,
- a $\bar{\lambda}_1 \in (\underline{\lambda}_2, \bar{\lambda}_2)$. $\Rightarrow \bar{\lambda}_1 \geq \underline{\lambda}_2$

Po transformácii tabuľky sa posledný riadok zmení nasledovne:

$$(\mu + \bar{\lambda}_1 v_r)' = \mu + \bar{\lambda}_1 v_r' \geq 0 \quad \dots \text{teda so zmenou}'$$

$$\text{Výpočet nových hodnôt: } \mu_j' = \mu_j - \frac{d_{sj} \cdot \mu_r}{d_{sr}} \quad v_j' = v_j - \frac{d_{sj} \cdot v_r}{d_{sr}}$$

$$\underline{\lambda}_2 = \sup_{v_j' > 0} \left\{ -\frac{\mu_j'}{v_j'} \right\}$$

$$\bar{\lambda}_2 = \inf_{v_j' < 0} \left\{ -\frac{\mu_j'}{v_j'} \right\}$$

20

(4x)

Pretvorí ζ zo indee bivierkej premennej, tak platí:

$$\nu_s^1 = \underbrace{\nu_s}_{=0} - \frac{1 \cdot \overbrace{\mu_s^1}^{<0}}{\underbrace{dsr}_{\geq 0}} \Rightarrow \nu_s^1 > 0 \Rightarrow \lambda_2 \geq -\frac{\mu_s^1}{\nu_s^1}$$

Dre dôkaz sporom predpokladajme, že $\bar{\lambda}_1 > \lambda_2 \Rightarrow \bar{\lambda}_1 > -\frac{\mu_s^1}{\nu_s^1} \Rightarrow \mu_s^1 + \nu_s^1 \cdot \bar{\lambda}_1 > 0$

Speciálne zo vzťahu: $(\mu + \bar{\lambda}_1 \nu)^1 = \mu + \bar{\lambda}_1 \nu$ vypĺňa:

$$(\mu_s^1 + \bar{\lambda}_1 \nu_s^1)^1 = \mu_s^1 + \bar{\lambda}_1 \nu_s^1 = \mu_s^1 + \bar{\lambda}_1 \nu_s^1 = 0$$

Pretvorí x_s bolo bivierké premenná, platí $\mu_s^1 = \mu_s$ a $\nu_s^1 = \nu_s$ (prvky vstupov)

$$\rightarrow \text{spor } \left. \begin{array}{l} (\mu_s^1 + \bar{\lambda}_1 \nu_s^1) > 0 \\ = 0 \end{array} \right\} \text{ nesúmerné}$$

Analogicky pre λ_1 (konečné).

$$x := x_2$$
$$y := x_3$$

$$\frac{4}{5}x + \frac{4}{3}y \leq 100$$

$$\frac{4}{5}x + y \leq 100$$



$$x + y \leq 100$$

$$x \leq 80$$

$$y \leq 80$$

$$4000x + 6000y = \text{Zisk}$$

$$y = \text{Zisk}^1 - \frac{2}{3}x$$



$$\text{Zisk}_1^1 = \frac{2}{3} \cdot 60 + 39 = 79$$

$$\text{Zisk}_2^1 = \frac{2}{3} \cdot 63 + 37 = 79$$

1. Gomoryho algoritmus

$$(1) \max_{M_C} c^T x \quad M_C = \{x \in \mathbb{R}^n \mid Ax = b, x \geq 0, x_i \in \mathbb{Z}, i \in C \in \{1, \dots, n\}\}$$

$b(A) = m, 1 \leq m \leq n, A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m$

Ispojitá náloha: (2) $\max_M c^T x \quad M = \{x \mid Ax = b, x \geq 0\}$

1) můžeme nálohu (2): a) neexistuje řešení, protože $M = \emptyset \Rightarrow M_C = \emptyset \Rightarrow$ konec.

Předpoklad: M je obmedřená, $C < \emptyset$.

Tento předpoklad nemusí být splněn v 1. Gom. alg.

Tu ho máme pro jednoduchost výkladu.

b) $\exists x^{\text{opt}} \in M_C \rightarrow x^{\text{opt}}$ je řešení (1) \rightarrow konec

c) $\exists x^{\text{opt}} \notin M_C \rightarrow$ rozbudoveme M (svorime se s náborovinou)

Určíme $k = \min_{i \in C} i \mid x_i^{\text{opt}} \notin \mathbb{Z} \}$

Předpoklad:

Pro dokaz konečnosti algoritmu musí platit $x_0 \equiv c^T x, 0 \in C$ (A.z. $c^T x \in \mathbb{Z}$).

k -tý řádek je poslední řádky matici A : $x_k = d_{k0} - \sum_{j \in N} d_{kj} x_j \quad (x_k^{\text{opt}} = d_{k0})$

$$(3) x_k = [d_{k0}] + \begin{cases} d_{kj} \\ \geq 0 \\ \leq 1 \end{cases} - \sum_{j \in N} [d_{kj}] x_j - \sum_{j \in N} [d_{kj}] x_j \Rightarrow -[d_{k0}] + \sum_{j \in N} [d_{kj}] x_j = -x_k + [d_{k0}] - \sum_{j \in N} [d_{kj}] x_j$$

Definujeme

$$(4) R = \{x \in \mathbb{R}^n \mid -[d_{k0}] + \sum_{j \in N} [d_{kj}] x_j = 0\}$$


Věta:

Pro náborovinu R a její průslužní polovrstvy

$$H^- = \{x \in \mathbb{R}^n \mid -[d_{k0}] + \sum_{j \in N} [d_{kj}] x_j \leq 0\}$$

$$\bar{H}^+ = \{x \in \mathbb{R}^n \mid -[d_{k0}] + \sum_{j \in N} [d_{kj}] x_j \geq 0\}$$

platí $x^{\text{opt}} \in H^- \wedge M_C \subset \bar{H}^+$.



Dôkaz:

Pre x^{opt} platí $x_j^{\text{opt}} = 0$, $j \in N$. Po dosadení do (4) dostaneme

$$-\boxed{d_{k0}} + \sum_{j \in N} \boxed{d_{kj}} \cdot 0 = -\boxed{d_{k0}} < 0 \Rightarrow x^{\text{opt}} \in H^-.$$

Zvolme $x \in M_c$ ľubovoľne pene a dosadime do (3):

$$\begin{aligned} -1 &\leq -\boxed{d_{k0}} \leq -\boxed{d_{k0}} + \underbrace{\sum_{j \in N} \boxed{d_{kj}}}_{\in \mathbb{Z}} x_j = -x_k + \boxed{d_{k0}} - \underbrace{\sum_{j \in N} \boxed{d_{kj}}}_{\in \mathbb{Z}} x_j \\ &\quad \leftarrow \quad \leftarrow \\ -\boxed{d_{k0}} + \sum_{j \in N} \boxed{d_{kj}} x_j &\geq 0 \Rightarrow x \in \bar{H}^+ \Rightarrow M_c \subset \bar{H}^+ \end{aligned}$$

Poznámka:

Pretože v ďalšom kroku budeme riešiť nálohu $\max_{M \cap \bar{H}^+} C^T x$, pridame ku poslednej tabuľke podmienku

$$-\boxed{d_{k0}} + \sum_{j \in N} \boxed{d_{kj}} x_j - x_{n+1} \geq 0 \rightarrow x_{n+1} = -\boxed{d_{k0}} + \sum_{j \in N} \boxed{d_{kj}} x_j$$

1. p. riadok

$$\boxed{-\boxed{d_{kj}}} \quad \boxed{-\boxed{d_{k0}}}$$

Pretože v poslednom stĺpci (hodnoty bázičkých premenných) je jediná záporná hodnota $-\boxed{d_{k0}}$, zvolme tento riadok za klíčový. Po ďalnej transformácii tabuľky posledný riadok opäť vymenčame.

Napäť tomu vo väčšom kroku riešime nálohu $\max_{M \cap \bar{H}_1^+ \cap \dots \cap \bar{H}_k^+} C^T x$.

Konečnosť

Za predpokladu, že M je obmedzená a $0 \in C$, je 1. gom. alg. konečný.

Jednoštvrť spojite nálohy riešime upravenou DSM, ktorej nazívame lexicografickou DSM (l -metódou).

Definícia:

Čiarka $x \in \mathbb{R}^n$ nazívame lexicograficky klasifikovanou (l -klassifikovanou), ak pre $i \in \{ \min \{ j \in \{1, \dots, n\} \mid x_j \neq 0 \} \}$ platí $x_i > 0$. Značenie: $x > 0$

Príklad: $x = (0, 0, 1, -100, -200, -300) > 0$

x_0	x_1	\dots	x_e	$0 \dots 0$	-1	$0 \dots 0$	0	$R_1 \dots R_{e-1} R_e$	R_n	R_0
x_0	x_1	\dots	x_e	$0 \dots 0$	-1	$0 \dots 0$	0			
x_n		\dots								
x_{n+1}		\dots								
x_r	$2x_1$	\dots	$2x_e$			b_r				
x_{n+m}		\dots								



x_0	x_1	\dots	x_e	$2x_1$	\dots	$2x_e$	b_r	$R_1 \dots R_{e-1} R_e$	$R_{n+1} \dots R_n$	R_0
x_0	x_1	\dots	x_e	$2x_1$	\dots	$2x_e$	b_r			
x_n		\dots								
x_{n+1}		\dots								
x_r	$0 \dots 0$	\dots	0	-1	$0 \dots 0$	0	0			
x_{n+m}		\dots								

Pravidlo transformací:

1. nominátor křížového rozdruhu máme $0 \dots 0 - 1 0 \dots 0 0$
2. křížový slype delme - $2x_e$
3. ostatní slype obvyklým sposobem

redukuje grafu (mel být upinej?...) bude pravé ta HK o delce n (počet vrcholu).

PISEMKA Z 7.2.2006:

- 1) Navrhnete hladový algoritmus který pro danou vstupní hodnotu x k čemuž navrhne poskladání x z minci v hodnotách 10, 5, 2, 1 ke tak, že je použit minimální možný počet mincí.
- 2) Dokazte správnost algoritmu b) nalezeného množinu hodnot minci, pro kterou vas algoritmus nebude fungovat, tj. nedosahne všechny minima (nemusí se jednat o existujici hodnoty minci)
- 3) Řešení: Algoritmus - vyberu největší hodnotu tolíkrat. Tolíkrat se vejdě a opakuji postupne pro menší. Nefunguje např. na 10, 9, 1 a $x = 27$ a mnoha dalších příkladech. Pozor ale, nestaci podmínka, že nasledující hodnota je alespoň dvojnásobek předchozí, viz např. 1, 4, 9 a $x=12$.
- 4) Důkaz: Uvedenoum si, že v nejlepším případě bude max 1 krát 5, 2 krát 2, 1 jedna 1 a pak zboru případu

- 2) Mame TSP (obchodní cestujici) Předpokládejte, že máte k dispozici černou skřinku resici TSP v polynomálním case. Navrhnete polynomální algoritmus, který pro Kn a w nalezně HK minimální hodnotu (výtupem algoritmu bude nalezena HK). Zdůvodněte, ze je nalezený alg. polynomální.

Riešenie: 1. verze

- 1) metodu plného intervalu zjistíš k)
 - 2) postupujes po te kružnici: likvidujes hrany z vrcholu ve kterém jsi kromě te po které jsi prisla (např. přišla k jejich dele k) a když ti CS začlasi ze přestala existovat tak kružnice, tak jsi nasedel/la další hranu. Tu pak vratis a pokracujes s vrcholem na jejím druhém konci.
2. verze
- Vezmu si první vrchol, a ohodnocuju hrany z nejdelšími nejakým $z > k$ (likvidace hran). Když mi CS rekne, že neexistuje TSP s ohodnocením $= k$, vratis původní ohodnocení této hraně / u ostatních nechavam $z/$ a pokracuju dalším vrcholem na druhém konci nalezené hraný. Tento mam rozhodovací problem, ale ja potrebuju optimalizaci, tak se musí dokařat, že i když budu binárně výhledávat, tak to porad bude polynomální. (to mi chybělo, neměl jsem to tedy "podrobne")

- 3) Problem 3R-SAT (SAT, kazda promenna max 3 vyskyty)
Dokáže ze je NPÚ.

Riešenie: Prevod ze SAT, pro každou promennou tam dam tolík nových $a_1 \dots a_n$, kolíkrat se vyskytuje a musíme pridat podmínu na ekvivalence $a_1 \leftrightarrow a_2 \dots \leftrightarrow a_n$. Potom jsem hotov. Ekvalenci $a_1 \leftrightarrow a_2$ muzu přepsat na $(a_1 \vee \neg a_2) \wedge (\neg a_1 \vee a_2)$, coz bych měl ale moc proměnných, fígl je v tom, že můsto ekvivalence napísat implikace do kolečka (to mi taky nepadlo). Cili $a_1 \rightarrow a_2 \rightarrow a_3 \rightarrow \dots \rightarrow a_n \rightarrow a_1$, tedy $(a_1 \vee a_2) \wedge (\neg a_1 \vee a_3) \dots \wedge (\neg a_n \vee a_1)$, tím vypílcam dva vyskyty a jeden mi zbyde do původní formule.

Definícia:

glovorime, že \mathbf{x} je lexicograficky väčšie ako \mathbf{y} ($\max_{\mathbf{x}, \mathbf{y} \in \mathbb{R}^n}$), ak platí $\mathbf{x} - \mathbf{y} \geq \mathbf{0}$.


Uvažme $\tilde{\mathbf{x}} = (\mathbf{c}^T \mathbf{x}, \mathbf{x}) = (x_0, \mathbf{x})$, kde $\mathbf{x} \in M$ a $\tilde{\mathbf{x}}$ bude následne nazývať rozšírením reieňom nálohy (2). Množinu všetkých rozšírených riešení označime \tilde{M} a platí $\tilde{M} = \{(x_0, \mathbf{x}) \in \mathbb{R}^{n+1} \mid x_0 = \mathbf{c}^T \mathbf{x}, \mathbf{x} \in M\}$.

Definícia:

$\tilde{\mathbf{x}}^*$ nazívame lexicograficky optimálnym (ℓ -optimálnym) riešením (2), ak platí $\tilde{\mathbf{x}}^* > \tilde{\mathbf{x}}, \text{ pre } \forall \tilde{\mathbf{x}} \in \tilde{M}, \tilde{\mathbf{x}} \neq \tilde{\mathbf{x}}^*$

Poznámka:

ℓ -optimálne riešenie je jedine a vždy existuje



Niek môže náloha n'�ore

$$\begin{aligned} \max_{M_C} \mathbf{c}^T \mathbf{x}, \text{ kde } \mathbf{c}^T \mathbf{x} = x_0 \\ M_C = \{(\mathbf{x}, \mathbf{x}') \in \mathbb{R}^{n+m} \mid A\mathbf{x} + \mathbf{x}' = \mathbf{b}, \mathbf{x}, \mathbf{x}' \geq \mathbf{0}, x_0, x'_j \in \mathbb{Z}, \forall j \in C\} \\ C = \{0, 1, \dots, n+m\}. \end{aligned}$$

Predpoklad: Prislušná M je obmedzená. $C < \mathbb{R}$.

$$\text{Z popisu } M = \{\mathbf{x}, \mathbf{x}' \mid A\mathbf{x} + \mathbf{x}' = \mathbf{b}, \mathbf{x}, \mathbf{x}' \geq \mathbf{0}\} \Rightarrow \mathbf{x}' = \mathbf{b} - A\mathbf{x}$$

$$\mathbf{x}' = \mathbf{0} - (-\mathbf{x})$$

$$\text{Z cieľovej funkcie: } x_0 = 0 - (-\mathbf{c}^T \mathbf{x})$$

Výhodisková ℓ -Tabuľka:

	R ₁ x ₁	R _n x _n	R ₀
x ₀	-c	0	
x ₁			
x ₂			
:			
x _n			
x _{n+1}			
:			
x _{n+m}	A	B	
:			
x _{n+m}			

Definícia:

Tabuľka T nazívame ℓ -normálnou, ak platí $R_j > 0$ pre $j = 1, \dots, n$.

Poznámka:

Z predpokladu $c < 0$ plynie, že výhodisková tabuľka je ℓ -normalná.

Tvrdenie:

Nedegenerované nejednoznačné bázické riešenie v ℓ -normálnej tabuľke je ℓ -optimálne.

Bez dokazu:

Uvedieme 3 vety ℓ -metódy pre 1. krok (platia rovnako v každom kroku).

1. veta ℓ -metódy

Ak platí $\bar{b} > \sigma$ (resp. $\bar{b} \geq \sigma$ a ε -modifikovaná tabuľka), potom máme ℓ -optimálne riešenie ($\mathbf{x}^{\text{opt}} = \bar{b}$, $\mathbf{x}^{\text{opt}} = \sigma$).

Dokaz:

Rovnaký ako v DSM.

2. veta ℓ -metódy

Ak existuje r takí, že $b_r < 0$, $a_{rj} \geq 0$ ($j=1, \dots, n$), potom je $M=\emptyset$ a neexistuje riešenie (2) a tiež ani (1).

3. veta ℓ -metódy

Nech nie sú splnené predpoklady 1. ani 2. vety ℓ -metódy.

$$\text{Definujme } l = \min_B \{i \in \{n+1, \dots, n+m\} \mid b_i < 0\}, \quad \text{lev. min}_{a_{rl} \geq 0} \frac{R_l}{|a_{rl}|} = \frac{R_l}{|a_{rl}|}.$$

Jednoznačne určený prvek $a_{rl} < 0$ je pivotom.

Prv transformáciu tabuľky doslaneme opäť ℓ -normálnu tabuľku.

Dokaz:

$$\text{„}l\text{“: } R_l = \frac{R_l}{\underbrace{-a_{rl}}_{>0}} > 0 \quad \text{„}j \neq l\text{“: } R_j = R_j - \frac{a_{rj} \cdot \overbrace{R_l}^{>0}}{\underbrace{-a_{rl}}_{>0}} > 0$$

$$2) a_{rj} \geq 0 \rightarrow \text{OK}$$

$$b) a_{rj} < 0. \quad \text{Z definície } l \Rightarrow$$

$$\Rightarrow \frac{R_l}{-a_{rl}} > \frac{R_j}{a_{rj}} \Rightarrow R_j > \frac{R_l \cdot a_{rj}}{-a_{rl}} \Rightarrow R_j > 0 \Rightarrow \ell\text{-normálna tabuľka}$$

$$\text{„}0\text{“: } R_0 = R_0 - \frac{a_{r0} \cdot \overbrace{R_l}^{>0}}{\underbrace{-a_{rl}}_{=0}} < R_0 \quad \square$$

Poznámka:

ℓ -metóda je konečná, pretože máme konečný počet báz a platí $R'_0 < R_0$ a tiež sa nikdy nemôžeme dostat do bázy, ktorú sme skôr uvažovali.

Metódy riešenia úloh nejednorémeho programovania

1. Metódy pripravných smerov (gradientné)

Vyhodeme z pripravného riešenia úlohy a) hľadame smer, v ktorom funkcia klesá,
b) hľadame dĺžku kroku

2. Metódy založené na K-T podmienkach

Výhodné v kvadratického programovania: $\min_M \{ \mathbf{x}^T C \mathbf{x} + p^T \mathbf{x} \}$, $M = \{ \mathbf{x} \mid A \mathbf{x} \leq b, \mathbf{x} \geq 0 \}$

3. Metódy vychádzajúcich aproximáciu (metódy nepravých smerov)

Množina pripravných riešení úlohy má vlastne "jednoduchú" možnosť (kveteným polyederom) a riešime novú úlohu. Ak leží optimálne riešenie v množine pravodlnej, OK.

4. Metódy vnitornej aproximácie

Metóda Franka a Wolfa

Úloha: $\min_M f(\mathbf{x})$, $M = \{ \mathbf{x} \in \mathbb{R}^n \mid A \mathbf{x} \leq b, \mathbf{x} \geq 0 \}$, $A \in \mathbb{R}^{m \times n}$, $b \in \mathbb{R}^m$

f - konkávna a má spojité 1. parciálne derivácie ∂M , ∂ - ohraničená mn.

Predpoklad: \mathbf{x}^r - hodnota \mathbf{x} v r-tom kroku


Funkcia $\nabla f(\mathbf{x}^r)(\mathbf{x} - \mathbf{x}^r)$ je zdola obmedzená na M pre $\forall \mathbf{x}^r \in M$.

(Tento predpoklad je splnený, keďže M obmedzená.)

Náplň:

Vyhodeme z vrcholu M . Riešime $\min_M \Theta$: $\begin{cases} \text{neexistuje riešenie} \Rightarrow M = \emptyset \Rightarrow \\ \Rightarrow \text{zádara úloha nemá riešenie} \\ \text{majdeme optimálny vrchol } \mathbf{x}^* \in M \end{cases}$


... pokračujeme. Nech $\hat{x}^r \in M$. Potom:



$$f(x^r + \lambda(\hat{x} - x^r))$$

dlžka kroku: $\hat{x} - x^r$

$$\hat{x}^{r+1} = \hat{x}$$



Poznáme $x^r \in M$.

Ovšem $\min_M V F(x^r)^T (x - x^r)$ dáva rovnaké opt. řešenie ako $\min_M V F(x^r)^T x$,

alemedíme sa na nív posledného kroku. Dôsime si kde $\min_M V F(x^r)^T x$.

Teda predpokladu existuje opt. řešenie $\hat{x} \in M$. Teda:

$$V F(x^r)^T (\hat{x} - x) \leq 0, \quad \forall x \in M, \quad V F(x^r)^T (\hat{x} - x^r) \leq 0.$$

1. Veta:

2. Veta:

Nach $\nabla F(\hat{x}^r)^\top (\hat{x} - \hat{x}^r) < 0$, $\nabla F(\hat{x})^\top (\hat{x} - \hat{x}^r) \leq 0$, potom počíme $\hat{x}^{r+1} = \hat{x}$, príčom platí $F(\hat{x}^{r+1}) < F(\hat{x}^r)$.

Dôkaz:

Načajme, že $F(\hat{x}^r + \lambda(\hat{x} - \hat{x}^r))$ pre $\lambda \in (0, 1)$.

$$\Psi(\lambda) = F(\hat{x}^r + \lambda(\hat{x} - \hat{x}^r)), \quad \lambda \in (0, 1)$$

$$\Psi'(\lambda) = \nabla F(\hat{x}^r + \lambda(\hat{x} - \hat{x}^r))^\top (\hat{x} - \hat{x}^r)$$

$$\Psi'(0^+) = \nabla F(\hat{x}^r)^\top (\hat{x} - \hat{x}^r) < 0 \Rightarrow \Psi(\lambda) \text{ klesá na } (0, \lambda^0], \quad \lambda^0 > 0 \Rightarrow \Psi(0) < \Psi(\lambda^0)$$

\leftarrow podľa predpokladu

Chceme overiť, či platí $\min_{(0,1)} \Psi(\lambda) = \Psi(1)$.

Pre dokaz sporom predpokladajme, že $\exists \lambda \in (0, 1)$ tak, že $\Psi(\lambda) < \Psi(1) \Rightarrow$
 $\Rightarrow F(\hat{x}^r + \lambda(\hat{x} - \hat{x}^r)) < F(\hat{x})$.

$$0 > F(\hat{x}^r + \lambda(\hat{x} - \hat{x}^r)) - F(\hat{x}) \geq \nabla F(\hat{x})^\top (\hat{x}^r + \lambda(\hat{x} - \hat{x}^r) - \hat{x}) = \\ = \underbrace{(1-\lambda)}_{\geq 0}$$

3. Veta:

Nach $\nabla F(\hat{x}^r)^\top (\hat{x} - \hat{x}^r) < 0$, $\nabla F(\hat{x})^\top (\hat{x} - \hat{x}^r) > 0$, potom definujeme

$\hat{x}^{r+1} \equiv \hat{x}^r + \lambda_r(\hat{x} - \hat{x}^r)$, príčom $F(\hat{x}^{r+1}) < F(\hat{x}^r)$ a λ_r je riešením rovnice $\nabla F(\hat{x}^r + \lambda(\hat{x} - \hat{x}^r))^\top (\hat{x} - \hat{x}^r) = 0$.

Dôkaz:

Funkcia $\nabla F(\hat{x}^r + \lambda(\hat{x} - \hat{x}^r))^\top (\hat{x} - \hat{x}^r)$ je nezáporná na $(0, 1)$.

Na záver sa dokazuje, že λ_r je $\Psi'(\lambda)$.

Daktož $\Psi'(0) = \nabla F(\hat{x}^r)^\top (\hat{x} - \hat{x}^r) < 0$ podľa predpokladu

a $\Psi'(1) = \nabla F(\hat{x})^\top (\hat{x} - \hat{x}^r) > 0$, musí $\exists \lambda_r \in (0, 1)$ tak, že $\Psi'(\lambda_r) = 0$,

8.
N. p. $\nabla F(\hat{x}^r + \lambda_r(\hat{x} - \hat{x}^r))(\hat{x} - \hat{x}^r) = 0 \Rightarrow$ našli sme x_r také, že $\hat{x}^{r+1} = \hat{x}^r + \lambda_r(\hat{x} - \hat{x}^r) \in M$.

$$F(\hat{x}^r + \lambda_r(\hat{x} - \hat{x}^r)) < F(\hat{x}^r), \text{ lebo } \min_{\{0,1\}} \psi(x) = \psi(x_r)$$

čiže $\psi'(x_r) = 0$.

Algoritmus (zhrnutie horuvedeného)

Uvodzny krok: Riešme $\min_M \theta$. Ak neskončí riešenie \rightarrow koniec, $M = \emptyset$.

Bežny krok r :

1. Riešime $\hat{x}^r \in M$. Nech optimálne riešenie vlohy $\min_M F(\hat{x}^r)^T(\hat{x} - \hat{x}^r)$ je $\hat{x} \in M$.
2. Ak je $\nabla F(\hat{x}^r)^T(\hat{x} - \hat{x}^r) = 0$, potom je \hat{x}^r opt. riešenia a koniec.
3. Ak je $\nabla F(\hat{x}^r)^T(\hat{x} - \hat{x}^r) < 0 \vee \nabla F(\hat{x})^T(\hat{x} - \hat{x}^r) \leq 0$, polož $\hat{x}^{r+1} = \hat{x}$, $r := r+1$,
čo dôjde na 1.

rozvoj klavučí až po II. sv. válce (samocínné počítací)

- obová lit.: A. Laščák a kol.: Optimalné programovanie (1983) (1)
- N. Maňas: Optimalizační metody (1979)
- E. Polak: Computational methods in optimization (1971)
- D.G. Luenberger: Introduction to linear and nonlinear programming (1973)

Dělení optimalizačních disciplín

Def 1: Uloha $\max_{x \in M} (min) f(x)$, kde $f(x): \mathbb{R}^n \rightarrow \mathbb{R}$, $M \subset \mathbb{R}^{k \times n}$

základními úlohami matematické optimizace (mat. programování)

I. Kriterium

- a) spojita optimizace - M konečná & spojitu posouvatelná
- b) diskretní optimizace - M konečná (spojitá) (kombinatorika)

II. Kriterium

- a) deterministická optimizace

- b) stochastická — náhodná pravděpodobnost (statistika)

III. Kriterium

- 1a) úloha má volný extremum ($\min_{x \in \mathbb{R}^n} f(x)$) ; $f: \mathbb{R}^n \rightarrow \mathbb{R}$ a rovná doména

• Penalizační a bariérové metody

$$P = \text{posloupnost } \min_{x \in \mathbb{R}^n} \{ f(x) + r_i b(x) \}$$

$$\beta = \min_{x \in \mathbb{R}^n} \{ f(x) + r_i b(x) \}$$

$r_i \rightarrow 0$

— můžeme také použít množinu M
polohy jež je v množině M

M

• M ... množina \Rightarrow přípustných řešení

• $f(x)$... cílová funkce (objektivum)

Def 2: Optimalním řešením optimalizační úlohy rozumíme $x^* \in M$ takové, že

$f(x) \geq f(x^*)$, $x \in M$ pro minimum cílové funkce na množině přípustných řešení

$f(x) \leq f(x^*)$, $x \in M$ pro maximum — u

2) užlohy na některých extrech $\min_{x \in M} f(x)$, $f: \mathbb{R}^m \rightarrow \mathbb{R}$, $M \subseteq \mathbb{R}^m$ (2)

$$M = \{x \in N \mid g_i(x) \leq 0, i=1, \dots, m\},$$


$$N \subseteq \mathbb{R}^n \quad g_i(x): \mathbb{R}^n \rightarrow \mathbb{R}, i=1, \dots, m$$

@ lineární programování

$$f(x) = \mathbf{c}^T x, \quad \mathbf{c} \in \mathbb{R}^m \quad (\text{lineární})$$

$$M = \{x \in \mathbb{R}^m \mid Ax \leq b, A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m\}$$

• existenciální věda (\exists) (existenciální theorem)



→ extremum nastává ve vrcholu (alespoň v 1)

• princip duality (průměrné \leftrightarrow podmínky)

→ primární & dualní simplexová metoda

@ ne-lineární programování

• alespoň 1 funkce f, g_i není lineární

• konvexní a zvlášt. konvexní programování

- f a g_i konvexní, spec.

- konvexní funkce \Rightarrow globální extremum = globální extremum

• nekonvexní programování

c) parametrické programování

• C_1 není 'pevné' $\xleftarrow{\subseteq} \xrightarrow{\supseteq}$ intervalová analýza

• rostoucí data mohou dát na pevné, ale dají se vyjádřit jako funkce dalších proměnných (parametry)

d) celočíselné programování

e) vícerozíšerné (vektorevé) programování

• elová funkce je vektorevá $f(x) \Rightarrow f_1(x), \dots, f_m(x)$

d) dynamické programování

• začínají na rozhodovacích procesech

a) diskrétní ... Bellmannův princip optimality

b) spojité ... Vypočítání optimální strategie je optimální.

Pontrajaginův princip optimality (maxima)

pokračování

a) a b)

g) korie her \Rightarrow matic je posluchač

(3)

h) semidefinisne' programovani'

$$\circ M = \{x \in \mathbb{R}^n \mid g_i(x) \leq 0, i=1, \dots\}$$

(2)

29.02.2008

Dopravní problem

1. klasický dopravní problem (úloha LP)

• formulace: Je dán výrobek V_1, \dots, V_m , které "vyrábí" jednu výrobek a možných $a_i > 0$ kč (ne stejně čas jednotce a stejných náklových jednotkách)

Je dán S_1, \dots, S_m spotřebiteli, kteří požadují tento výrobek a $b_j > 0$ kč (ne stejně + ...)

Je dán $c_{ij} \geq 0$ kč, cena za dopravu jednotky výrobku V_i do S_j .

Předp: Náklady na dopravu rostou lineárně!

• Nezamítej: x_{ij} -- množství výr., který dodá výrobce V_i spotřebiteli S_j kč

$$M = \{x_{ij} \in \mathbb{R}^{m \times m} \mid \sum_{i=1}^m x_{ij} = b_j, \sum_{j=1}^m x_{ij} = a_i, x_{ij} \geq 0 \text{ kč}\}$$

chceme, aby byla splněna podmínka ekonomické normality

$$\sum_{i=1}^m a_i = \sum_{j=1}^m b_j$$

pokud nejsme pak si domysleli
fikтивního spotřebitele a výrobce
s velmi velkými cenami \Rightarrow
 \Rightarrow nepoužíje se v optimu

$$\min_{\{x_{ij} \in M\}} \sum_{i=1}^m \sum_{j=1}^m c_{ij} x_{ij}$$

• nepoužívej simplexovou metodu, ale vlastní, s tabulkou $m \times m$
- simplex $m \times n$ prov, $m+n+m+n$ I

2. Dopravní problem s lineárními cenami dopravy (úloha me linear. progr.)

• stejná formulace, ale $c_{ij}(x_{ij}) = d_{ij} + e_{ij} \cdot x_{ij}$

$$\min_M \sum_{i=1}^m \sum_{j=1}^m (d_{ij} x_{ij} + e_{ij} x_{ij}^2) \quad (\text{kвадратична' uloha})$$

3. Dopravní problém s cestovními podmínkami

- stejná formulace, ale $M_C = \{x_{ij} \in \mathbb{R}^{m \times n} \mid \sum_{i=1}^m x_{ij} = b_j, \sum_{j=1}^n x_{ij} = a_i, x_{ij} \geq 0\}$
 $\min_{M_C} \sum_{i=1}^m \sum_{j=1}^n c_{ij} x_{ij}$

4. Dopravní problém parametricky (parametrické programování)

- Formulace je stejná, ale $a_i \sim a_i + \lambda a'_i$ kde $\lambda \in \mathbb{R}$

Potom $M_{(\lambda)}^* = \{x_{ij} \in \mathbb{R}^{m \times n} \mid \sum_{i=1}^m x_{ij} = b_j, \sum_{j=1}^n x_{ij} = a_i + \lambda a'_i, x_{ij} \geq 0\}$

$$\min_{M_C} \sum_{i=1}^m \sum_{j=1}^n c_{ij} x_{ij}$$

- může hledat obory stability - $\{\lambda\}$ je stejným řešením
obor reálnosti $\{\lambda\}$ pro λ než všecky jiné řešení

5. Dopravní problém jako úloha měkkého programování

- nejen minimizovat cenu přepravy, ale i maximizovat zisk

- stejná formulace, ale \leq cílové funkce $\min \sum_i \sum_j c_{ij} + \alpha x_{ij} \rightarrow$ tedy min

$$\min_M \left\{ \sum_i \sum_j c_{ij} x_{ij} - \sum_i z_i \right\} \quad \sum_i z_i \rightarrow \max$$

6. Dopravní problém jako úloha dynamického programování

$c_{ij}(x_{ij})$ - různé funkce x_{ij} k i, j . $\min \sum_{i,j} c_{ij}(x_{ij})$

rozdělovací $0 \leq x_{ij} \leq \alpha$; $\alpha = (a_1, \dots, a_m)$ k $j = 1, \dots, m$.

$$\sum_i w_{ij} = b_j \quad k_j$$

stanovit x_j - množství výrobku, které bude rovnás v j -ém kroku

$$0 \leq x_j \leq \alpha$$

- zadán počáteční stav $x_1 = \alpha$

$$\dots x_2 = x_1 - \text{objekt } w_1$$

Přehled následků lineárního programování

(5)

Def 3: Množina $\{x \in \mathbb{R}^m \mid Ax \leq b; a \neq 0, a \in \mathbb{R}^n, b \in \mathbb{R}\}$
nazývaná ^{uzavřený} poloprostor v \mathbb{R}^m .

Množina $\{x \in \mathbb{R}^m \mid Ax = b; a \neq 0, a \in \mathbb{R}^n, b \in \mathbb{R}\}$ nazývané
nadrovninou (podprostor dimenze $m-1$)

Příklad konečného počtu nadrovin a uzavřených poloprostorů nazývané
konečným polyédrem.

Def 4: Uloha LP v rovnicovém tvare má základní učebniční podobu

$$\min_{M'} C^T x ; M = \{x \in \mathbb{R}^n \mid Ax = b, x \geq 0\}, A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m, C \in \mathbb{R}^n.$$

Simplexová metoda požaduje:

1) učebniční LP v rovnicovém tvare

2) $b \geq 0$

3) $\not\exists I_m \sim A$

4) $1 \leq m < n$

5) $h(A) = m$

Převody (z normálního tvaru do rovnicového tvaru)

a) $Ax \leq b \geq 0 \rightarrow Ax + \xi = b; \xi \geq 0; \min_{M'} \{C^T x + 0^T \xi\}$

$$M' = \{x, \xi \mid Ax + \xi = b; x \geq 0; \xi \geq 0\}$$

doplňkové proměnné

b) $Ax \geq b \geq 0 \rightarrow Ax - \xi = b; \xi \geq 0$

$$Ax - \xi + w = b, \xi, w \geq 0$$

↑ vznikla učebna - jiný problém

$$\min_{M_K} C^T x + K^T w \quad K = K_1, \dots, K_m \quad K_i > 0$$

$$M_K = \{x, \xi, w \in \mathbb{R}^{m+2m} \mid Ax - \xi + w = b, \\ x, \xi, w \geq 0\}$$

ponovení do prostoru vyšší dim., ale problém je stejný

nebo provedeme první etapu

$$\min_{\mathbf{x}} \sum_{i=1}^m u_i$$

(6)
opt. řeš. $u = 0 \Rightarrow$ máme vých. řeš.
adané úlohy a pokračujeme SA, ale
musíme dopod'bat krit. nálež.

c) $M = \{ \mathbf{x} \mid A \mathbf{x} = \mathbf{b} \}$

$$\mathbf{x} = \mathbf{x}^+ - \mathbf{x}^- \quad x_i^+ = \max \{ 0, x_i \} \geq 0$$

$$x_i^- = \max \{ 0, -x_i \} \geq 0$$

$$M = \{ \mathbf{x}^+, \mathbf{x}^- \in \mathbb{R}^{2n} \mid A \mathbf{x}^+ - A \mathbf{x}^- = \mathbf{b}, \mathbf{x}^+ \geq 0, \mathbf{x}^- \geq 0 \}$$

$$\min_M \{ C^T \mathbf{x}^+ - C^T \mathbf{x}^- \}$$

f_i

Přepis úlohy LP v rovnicovém tvare

je předp. $h(A) = m \Rightarrow \exists$ konečný počet reg. matic $A_i \subset A$

Dále (BÚNO) $A = (A_B, A_N)$, kde A_B je reg. matici $m \times m$

Potom $A \mathbf{x} = \mathbf{b}$ psáme $A_B \mathbf{x}_B + A_N \mathbf{x}_N = \mathbf{b}$, kde $\mathbf{x} = (\mathbf{x}_B, \mathbf{x}_N)$

Stejným způsobem rozdělíme $C = (C_B, C_N)$. Potom můžeme adanou úlohu přepsat na tvor $\min_A (C_B^T \mathbf{x}_B + C_N^T \mathbf{x}_N)$.

$$M = \left\{ \mathbf{x}_B, \mathbf{x}_N \mid \mathbf{x}_B = \underbrace{A_B^{-1} \mathbf{b}}_{A_B^{-1} \mathbf{b}} - \underbrace{A_B^{-1} A_N}_{D} \mathbf{x}_N \geq 0, \mathbf{x}_N \geq 0 \right\} \equiv \\ \equiv \left\{ \mathbf{x}_B, \mathbf{x}_N \mid (\mathbf{x}_B =) d^0 - D \mathbf{x}_N \geq 0, \mathbf{x}_N \geq 0 \right\}$$

$$C_B (A_B^{-1} \mathbf{b} - A_B^{-1} A_N \mathbf{x}_N) + C_N \mathbf{x}_N = \underbrace{C_B^T A_B^{-1} \mathbf{b}}_{C_0} + \mathbf{x}_N (C_N - C_B A_B^{-1} A_N)$$

$$= C_0 + (C_N - Z_N)^T \mathbf{x}_N$$

$d^0 = A_B^{-1} \mathbf{b}$
$D = A_B^{-1} A_N$

Ak posíme libovolný linn. B (tj. libovolné nezávislé lini. funkce), potom se
 $\min_M \{ C_0 + (C_N - Z_N)^T \mathbf{x}_N \}$ má náležitá přepsat na tvor:

Pozn: V SymMet je každá $A_B = E \Rightarrow A_B^{-1} = E$.

Def 5: X_B nazýváme rektorem basickej proměnných, X_N nazýváme rektorem nebasickej proměnných.

$(X_B, X_N) = (d^0, \sigma)$ nazýváme basickej řešením. Je-li $d^0 \geq \sigma$, pak mluvíme o průjivné basickej řešení. Je-li $d^0 > \sigma$, pak jde o nedegerované průj. baz. řeš.

Hodnota a'love' funkce v průj. baz. řeš. je $C_X = C_0$.

Tabulka SM

	c_B X_B	c_N X_N	d^0	T
c_B X_B	1 ...	D	d^0	$m+1$
0	0	$c_N - z_N$	$-C_0$	- kriterium rádeku

1. V. SM: Jestliže $n + T$ plní $c_N - z_N \geq \sigma$, potom je průj. baz. řeš. (d^0, σ) je optimální!

2. V. SM: Existuje-li v T sloupec k $c_k - z_k < 0$, $d_{ik} \leq 0$ $i \in B$, potom neex. řešení zadání úlohy.

150
150

3. V. SM: Nejsou-li splněny předpoklady 1. ani 2. V. SM, potom klicový sloupec $\min_{j \in N \setminus \text{rádek}} (c_j - z_j) \equiv c_n - z_n$.

Klicový rádek určíme jako $\min_{i \in B} \left\{ \frac{d_{io}}{d_{is}} \right\} \equiv \frac{d_{r0}}{d_{rs}}$ a provedeme transformaci T s pivotem $d_{rs} \neq 0$. Dostaneme nové první řadu (X'_0, X') , kde $X' = C_T X$, kde

Pozn: Blandovo pravidlo požaduje $\min_{j \in N} \{c_j - z_j\} \equiv c_n - z_n$ a

$$\min_{i \in B} \left\{ \frac{d_{io}}{d_{is}} \right\} = \min_{i \in B} \left\{ \frac{d_{io}}{d_{ir}} \right\} \equiv c_j - z_j < 0$$

pro důkaznice 1. přístup

definujeme $s = \min \{j \in N, c_j - z_j = 0\}$ a $r = \min \{i \in B \mid \min_{i \in B} \left\{ \frac{d_{io}}{d_{is}} \right\} = \left\{ \frac{d_{ro}}{d_{rs}} \right\}\}$,

(nejmenší index, pro který)

(nejmenší index)

potom při aplikaci SM nemůže existovat kruhový cyklus.

Definice 6: Minimální $M_{\text{opt}} = \{x^* \in M \mid \min_M c^T x = c^T x^*\}$ nazýváme (8) minimálními všechny opt. řeš. úlohy LP.

Je-li $x^* = (d^*, 0) \geq 0$ je opt. řeš. zvané 'SM'. Nechť $c_N - z_N \geq 0$ jsou hodnoty z poslední ('optimální') tabulky. Označme $J = \{j \in N \mid c_j - z_j > 0\}$ a nechť C_0 je opt. hodnota cílové funkce. Pro $j \in N - J$ je $c_j - z_j = 0$.

Veta 1: Platí $M_{\text{opt}} = \{x \in M \mid x_j = 0, j \in J\}$.

Důkaz: Pro $\forall x \in M$ platí $c^T x = C_0 + (C_N - z_N)^T x_N = \underline{\underline{C_0}}$

$$= C_0 + \sum_{j \in J} (c_j - z_j) x_j + \sum_{j \notin J} (c_j - z_j) x_j = \underline{\underline{0}}$$

Hledáme ta $x \in M$, kde májí vlastnost $c^T x = C_0$

$$\Rightarrow C_0 + (C_N - z_N)^T x_N = C_0 + \sum_{j \in J} \underbrace{(c_j - z_j)}_{> 0} \underbrace{x_j}_{\geq 0} = C_0 \Rightarrow x_j = 0 \quad j \in J \quad \boxed{X}$$

• Prakt ... za když sloupec se nazve jde o hodnotu = 0.

• Nejde-li řeš. jedine' \Rightarrow je jich mnoho.

Degenerace, Cyklus, Vznik a odstranění!

Def 7: Říkame, že u SM nastává degenerace, jestliže alespoň 1 prázdný bar. řeš. je degenerované.


Je-li prázdný bar. řeš. $(d_0, 0)$ degen. $\Rightarrow d_{i,0} = 0$ alespoň pro 1 $i \in B$.

Je-li speciálne $i = \underline{\underline{r}}$, potom po tabulk. $-c_0 = -c_0 - \frac{(c_0 - z_r) \cdot d_{r,0}}{d_{r,r}}$

\Rightarrow nemén' se hodnota cílové funkce, t.j. $c^T x' = c^T x$

Mohlo by se stát, že $x^l \rightarrow x^{l+1} \rightarrow \dots \rightarrow x^l \rightarrow x^l$, príčemž

$c^T x^l = c^T x^{l+1} = \dots = c^T x^l = c^T x^l$. Nastal by tedy cyklus a SM by selhala.




y lze vyjádřit 3-mi
drobnějšími rovnicemi

\Rightarrow ten samý bod, ale jinak
vyjádřený

Význam degenerace

1) zadání ($b_i = 0$ ale sporů pro $1 \leq i \leq m$)

2) Nejdnoznamenatější výberu klič. rádku mítan $\left\{ \frac{d_{r0}}{d_{rs}} \right\} = \frac{d_{r0}}{\frac{d_{rs}}{d_{rs}}} = \frac{d_{r0}}{d_{rs}}$ (4)



$$d_{r0}' = d_{r0} - \frac{d_{rs} \cdot d_{r0}}{d_{rs}}$$

$$\Leftrightarrow d_{r0}' = 0 \quad (d_{r0})$$

výbereme r za index. hl. řeš. a $d_{r0}' = 0 \Rightarrow$ degener. průpr. hl. řeš.

Tvrdění: Při použití Blandova pravidla vznikají cykly při výpočtu SM

E-modifikovaná užloha LP

Def užlohu LP užlohu min $C^T x$; $M(\varepsilon) = \left\{ x \in \mathbb{R}^n \mid Ax = b + P(\varepsilon), x \geq 0, \varepsilon \geq 0 \right\}$ (kritika)

je-li $A = (E, A_N)$, potom poslední sloupec tabulky bude tvaru

$$b + (E A_N) \varepsilon, \text{ kde } \varepsilon = (\varepsilon_1, \varepsilon_2, \dots, \varepsilon_m) \Rightarrow \begin{cases} b_1 + \varepsilon_1 + \sum_{j=1}^m a_{1j} \varepsilon_j \\ \vdots \\ b_m + \varepsilon_m + \sum_{j=1}^m a_{mj} \varepsilon_j \end{cases}$$

o myslím si $\varepsilon > 0$ tak, aby $\sum_{j=m+1}^m a_{ij} \varepsilon_j$ nepřevyšovali ε^m

ad 1) neprípadná je užloha

ad 2) při hledání klič. ř. je možný

pivot $x_{ij} \neq x_{rs}$
 $r \neq p$

$$\frac{d_{r0} + \varepsilon + \sum_{j=1}^m d_{rj} \varepsilon^j}{d_{rs}} \neq \frac{d_{p0} + \varepsilon + \sum_{j=1}^m d_{pj} \varepsilon^j}{d_{ps}}$$

(4)

14.03.2008

Pozn: SM je konečná (pokud vznikají cykly) protože přípustných základních řešení je konečný počet.

Výpočetní složitost u SM

1. Nejhorší počet kroků SM je $(m)^m$

2. Při přechodu od jedné řešení k druhé mimo krokovitou cílovou funkci může:

$$-C_0' = -C_0 - \frac{(c_{j*} - z_{j*})}{d_{rs}} d_{p0}$$

přechod m. k některému
ale k nejlepšímu souřešení



a bychom měli nejméně možný počet kroků, tak

$$\min \left\{ \frac{(c_{j*} - z_{j*}) d_{r0}}{d_{rs}} \right\} = \frac{c_{j*} - z_{j*}}{d_{rs}} \quad \begin{array}{l} \text{* index} \\ \text{řešení} \\ \text{řešení} \end{array}$$

Při $m=50; m \leq n$ je # kroků při použití Bl. pravidla 95 & 59

3. Převeděpodobnostní metody

• horní odhad #kroků: $P(m, m) \leq m^{\frac{1}{m-1}} (m+1)^4 \cdot \frac{2\pi}{5} \left(1 + \frac{e\pi}{42}\right)$

(10)

4. Praktické problémy → #kroků nazávisí na m a je $\in (2m, 3m)$

5. Novější výzkumy $m < 50$, $m < 150$ je $P < \frac{3}{2}m$. (Plati tedy pro všechny následující.)

Algoritmy řeš LP - už loby:

1. Elipsoidová metoda (Chernav) 1979




elipsoid - na 1/2 & nový tan, kde je M

→ konec el obrahje M a opět je střed

• polynomialně

2. Karmarkarova projektivní metoda 1984 → polynomialně



Princip duality

Def: Ulohu LP se nazývá normální uloha

$$(P) \max_{M_1} C^T x, M_1 = \{x \in \mathbb{R}^n \mid Ax \leq b, x \geq 0\}, A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m$$

nezávazné primární ulohou a ulohou se nazývá normální uloha

$$(D) \min_{M_2} b^T y, M_2 = \{y \in \mathbb{R}^m \mid A^T y \geq c, y \geq 0\}$$

nezávazné dvojité ulohou LP.

$$y \begin{array}{|c|c|} \hline & A & | b \\ \hline \end{array}$$

Lemma 1: Je-li $M_1 \neq \emptyset, M_2 \neq \emptyset$ potom platí $C^T x \leq b^T y, \forall x \in M_1, y \in M_2$.

Dk: $M_1 \neq \emptyset \Rightarrow \exists x: Ax \leq b / y \quad x \geq 0 \} \Rightarrow y^T A x \leq y^T b \}$
 $M_2 \neq \emptyset \Rightarrow \exists y: A^T y \geq c / y \geq 0 \} \quad x^T A^T y \geq x^T c \} \Rightarrow$
 $\Rightarrow C^T x \leq b^T y \quad \hookrightarrow y^T A x \geq C^T x$

Lemma 2: Je-li $M_1 \neq \emptyset, M_2 \neq \emptyset$, potom zhodného sup $C^T x$ na M_1 a
zhodného inf $b^T y$ na M_2 .

Jk: $\neq L1 \Rightarrow$ průsečík 'volbe' $y^* \in M_2$, že platí $C^T x \leq b^T y^*, \forall x \in M_1$
 $\Rightarrow \exists m_1 = \sup_{M_1} C^T x$

$\neq L2 \Rightarrow \dots \quad x^* \in M_1, \dots \quad C^T x^* \leq b^T y_1, \forall y_1 \in M_2$
 $\Rightarrow \exists m_2 = \inf_{M_2} b^T y_1$

Lemma 3: Nechť $M_1 \neq \emptyset$ a $\exists m_1$ (resp. $M_2 \neq \emptyset$ a $\exists m_2$), potom je (P)
 $y^* \in M_2$ tel. st plati $b^T y^* \leq m_1$.
 (resp. $\exists x^* \in M_1$, st plati $c^T x^* \geq m_2$).

Důk: (z Farkasovy v.)

Věta: (Princip duality)

je-li $M_1 \neq \emptyset$; $M_2 \neq \emptyset$, potom \exists opt. řeš. x^* užity (P) a opt. řeš. y^* užity (D) a platí $c^T x^* = b^T y^*$.

$$\text{Důk: } \& L2 \Rightarrow \exists m_1, m_2 \stackrel{L3}{\Rightarrow} \exists x^* \in M_1 \Rightarrow c^T x^* \geq m_2 \stackrel{L1}{\Rightarrow} m_1 \geq b^T y^* \stackrel{L3}{\Rightarrow} c^T x^* \stackrel{L1}{\geq} b^T y^* \Rightarrow c^T x^* = m_2 = m_1 = b^T y^* \quad \square$$

Důsledky:

1) Ma-li jedna z užit (P) nebo (D) opt. řeš., pak ho má i druhá a platí rovnost funkčních hodnot opt. řeš. obouch. (+ autor Princip duality)
 (Ma-li (P) opt. řeš. $\Rightarrow M_1 \neq \emptyset \exists m_1 \stackrel{L3}{\Rightarrow} \exists y^* \in M_2$, a tedy $M_2 \neq \emptyset$ a jsem splněn půdpr. Principu duality)

2) Je-li $c^T x$ akora neomezena na M_1 , potom je $M_2 = \emptyset$.

(Je-li $b^T y$ akola neomezena na M_2 , potom je $M_1 = \emptyset$)

3) Souvislost opt. řešení:

je-li x^* opt. řeš. užity (P) $\Rightarrow A x^* \leq b$, $x^* \geq 0$. Označme $a_i^T x^* \leq b_i$, $i \in I_1$, $a_i^T x^* < b_i$, $i \notin I_1$, $(x_j^*) = 0$, $j \in J_1$, $x_j^* > 0$, $j \notin J_2$.

Potom $M_{\text{opt}}(D) = \{ y^* \in M_2 \mid y_{i,j}^* = 0 \forall j \notin I_1, y_j^* a_j^T = c_j \forall j \notin J_2 \}$

$$(z L1 a PD \Rightarrow c^T x^* = y^* A x^* = b^T y^* \Rightarrow (c - y^* A) x^* = 0)$$



$$= \sum_{j \in I_1 \cup J_1} (c_j - y^* a_j^T) x_j^* + \sum_{j \notin J_1} (c_j - y^* a_j^T) x_j^* = 0$$

$$\Rightarrow c_j = y^* a_j^T \quad j \in J_1$$

$$\Rightarrow y^* (A x^* - b) = 0 \Rightarrow \sum_{i \in I_1} y_i^* (a_i^T x^* - b_i) + \sum_{i \notin I_1} y_i^* (a_i^T x^* - b_i) = 0$$

$$\Rightarrow y_i^* = 0 \quad i \notin I_1$$

4) Rovnost $C^T x = b^T y_1$ plati právě v optimální hodnotě.
 \Leftrightarrow (PD \Rightarrow je-li x^* , y^* opt řešení (P), (D)) $\Rightarrow C^T x^* = b^T y_1$
 \Rightarrow Předp. že x^* není opt řešení (P) $\Rightarrow C^T x^* < C^T x^{opt} \leq b^T y_1$
 a podle předp. plati $C^T x^* = b^T y_1$ → náleží řešení spor.)



(biečné nepríporiadne) řešení (P)

$$\underline{A^T x^0 = B^T y^0}$$

$\underline{g_1^0} \in M_2$ nesem! (D)

$$C^T x^i = b^T y^i \quad , \quad y^i \in M_2 \quad \forall i$$

$$C^T \mathbf{x}^k = B^T \mathbf{x}_M^k, \quad \mathbf{x}^k \in M, \quad \Rightarrow \text{opt}$$

For more info see simplex.

5

21.03.2008

Zyawem'se Inn

Necht' nejaka' ST

x_1	x_n	x_m	x_{m+1}	x_r	x_n
E	0 ⋮ 0			d_m ⋮ d_m	D ⋮ D
x_D	1			d_{mr} ⋮ d_{mr}	
x_m	0 ⋮ 0				
0	0			$f_N - z_N$	$-c$

x_1	x_2	x_{r-1}	x_r	x_m
$\frac{1}{2}$	$\frac{1}{2}$		0	
$\frac{1}{2}$	$\frac{1}{2}$		\vdots	
$\frac{1}{2}$	$\frac{1}{2}$		0	
\curvearrowleft				
x_1	B_{32}		1	
			0	
			\vdots	
			0	
		$C_4 - \bar{e}_4$		0
		$\frac{1}{2}x_1$		

A diagram showing a grid of points. The vertical axis has points labeled x_1 , x_{m+1} , x_r , x_m , x_s , and x_m . The horizontal axis has points labeled $C_N - z_W$ and x_m . There are arrows indicating movement or flow between the points.

$$-\frac{c_n - z_n}{d_{sn}}$$

$$-\frac{c_n - z_n}{d_{sr}}$$

Pravidlo: Nejjprve transf. klínový sloupec tak, že na něj se
píšete ježího převrácená hodnota a ostatní
prvky kl. sloupců dle této (-převrácené). Ostatní prvky tabule
se transformují obvyklým způsobem.

Ducim 'simplexova' me soda

$$\begin{aligned} & \text{Dual problem: } \min_{\mathbf{x}} \mathbf{c}^T \mathbf{x}, \quad M_1 = \left\{ \mathbf{x} \in \mathbb{R}^m \mid \mathbf{A} \mathbf{x} \leq \mathbf{b}, \quad \mathbf{x} \geq \mathbf{0} \right\} \quad \mathbf{A} \in \mathbb{R}^{m \times n}, \quad \mathbf{b} \in \mathbb{R}^m \\ & \text{Moore (P) max}_{\mathbf{x}} \mathbf{c}^T \mathbf{x}, \quad M_1 = \left\{ \mathbf{x} \in \mathbb{R}^m \mid \mathbf{A} \mathbf{x} \leq \mathbf{b}, \quad \mathbf{x} \geq \mathbf{0} \right\} \\ & \text{Dual problem: } \max_{\mathbf{y}} \mathbf{b}^T \mathbf{y}, \quad M_2 = \left\{ \mathbf{y} \in \mathbb{R}^m \mid \mathbf{A}^T \mathbf{y} \geq \mathbf{c}^T, \quad \mathbf{y} \geq \mathbf{0} \right\} \end{aligned}$$

Sestavme ekvivalentní ulohy:

$$(7') \max_{M_1'} C^T x \text{ i } M_1' = \left\{ (x^*, x') \in \mathbb{R}^{n+m} \mid Ax + x' = b; x, x' \geq 0 \right\}$$

$x^* = (x_{m+1}, \dots, x_{m+m})$

mejor dual'ne'

$$(3') \min_{\substack{M_2 \\ M_2}} \text{by } M_2' = \left\{ (y, y') \in \mathbb{R}^{m+n} \mid A^T y - y' = 0; y, y' \geq 0; y' = (y_{m+1}, \dots, y_{m+n}) \right\}$$

Předpoklad: $C \leq 0$ (nejsou nutny, ale zeblocky)

Výchozí základní řešení u'loh (P') a (\perp'):

$(*, *)^o$: $*^o = 5$; $*^o = 15 \rightarrow$ je 'basicle', nemus' byt proprieté

$(y^0, y^1)^{\circ} : \quad y^0 = 0 ; \quad y^1 = -C > 0 \rightarrow$ prípusne 'závčie' reš - a $b^T y^0 = 0$

P'chox' Tabulka dual'm' sm-i

<u>Pychos' tabulka dualni' sm.:</u>		y_{m+n}	y_1
(x₁)	x_1		x_m
y_n	x_{m+1}	A	b
:	:		
y_{m+n}	x_{m+m}	- c	0

objektiv v jedné řadě

← Mendelsohn SM (Very nice male)

To Radcock (P'). To Alcock (D').

k-ay krok

$$\begin{pmatrix} y_1 & y_1' \\ x_1 & x_1' \end{pmatrix}_N B_d$$

$(y_1 y_1^*)_{N_A}$	$(*, *)_{B_B}$	D	d_{00}
		d_{30}	d_{00}

三

- prijmašte živčke wevera alohy (D)

$$(y_1 y^*)_{B_1} = \emptyset \geq \emptyset, \quad (y_1 y^*)_{N_1} = \emptyset$$

- břízka včetně vlohy (\mathbb{P}^1)

$$(\mathbf{x}, \mathbf{x}')_B = 0 \quad | \quad (\mathbf{x}, \mathbf{x}')_N = \sigma$$

Obrázek rovných hodnot celobojcích funkcií doo.

1. Věta DSM:

(14)

Plati - li v k - řešiv řešení DSM $d^* \geq 0$, potom $(x, x')_B = d^*$, $(x, x')_N = 0$. Jej opt. řeš. užitky (P') s hodnotou a'love' funkce d_{00} a příslušná část (x_B, x_N) jej opt. řeš. užitky (P) s opt. hodnotou a'love' funkce d_{00} .

Dále $(y, y')_{B_d} = d^*$, $(y, y')_{N_d} = 0$ je opt. řeš. užitky (D'), přičemž příslušná část (y_{B_d}, y'_{N_d}) je opt. řeš. užitky (D) s opt. hodnotou a'love' funkce d_{00} .

Dk: Protože $[(x, x')_B, (x, x')_N] \in M'_1$ a


$[(y, y')_{B_d}, (y, y')_{N_d}] \in M'_2$ (vzády)

$$\stackrel{\text{dále}}{\Rightarrow} (x_B, x_N) \in M_1 \quad \& \quad (y_{B_d}, y'_{N_d}) \in M_2 \Rightarrow$$

\Rightarrow protože $C^T x = b^T y = d_{00}$ (podle důsledku PD)

Optimalita x resp. y pro užitky (P) resp. (D)

weak. řeš.



$$A^T y - j' = \epsilon$$

$$j' = -\epsilon + A^T y$$

$$\text{Užitky: } M \text{ bolo: } x_B = b - Ax_N$$

2. Věta DSM:

Existuje - li index $s \in B$ tak, že $d_s^* < 0$ a $d_{sj} \geq 0$, $j \in N$.

Potom neexistuje řeš. užitky (P), (D).

Dk: s - ty rádky posl. tabulek zapíšme

$$x_s (\text{resp. } x'_s) = d_s^* - \sum_{j \in N} \underbrace{d_{sj}}_{> 0} \underbrace{(x, x')_j}_{\geq 0} < 0,$$

ale M'_1 má $(x_s, x'_s) \geq 0 \Rightarrow M'_1 = \emptyset \stackrel{\text{dále}}{\Rightarrow} M_1 = \emptyset \Rightarrow$

\Rightarrow neex. řeš. (P) $\stackrel{PD}{\Rightarrow}$ weak. řeš. (D)

3. Věta DSM:

(15)

Nechť nejsou splněny předpoklady 1. ani 2. VD SSM.

Poznáme

$$\min \{ i \in B \mid d_i^* < 0 \} = \tilde{d}_s \leftarrow \text{index nultky}$$

$$\min_{r \in B} \left(\min_{\substack{j \in B \\ d_{sj} < 0}} \left\{ \frac{\tilde{d}_s}{|d_{rj}|} \right\} \right) = \frac{\tilde{d}_s^*}{|d_{sr}|} \quad r = \text{index sloupce}$$

po transformaci tabulky (s dodatečnou pravidlem rozdružicím, že E chybí) dostaneme průstřední báz. řeš. $(y, y')^* \text{ ulohy } (D')$ a obecně báz. řeš. $(x, x')^* \text{ ulohy } (P')$ přičemž hodnota cílových funkcí v nichto báz. řešeních je $d_{oo}^* = d_{oo} - \frac{\tilde{d}_s^* \cdot d_s}{d_{sr}}$

a platí $d_{oo}^* \leq d_{oo}$. Nenásilna! - li degenerace platí $d_{oo}^* < d_{oo}$.

Dk: $|d_{sr}| < 0$

$$(y, y')^*: \tilde{d}_j^* = \tilde{d}_j^* - \frac{d_{sj} \cdot \tilde{d}_s^*}{d_{sr}}$$

členech sloupcu řádku ≥ 0

průstřední báz. řešení $y^* \geq 0$.

pokud $d_{sj}^* > 0 \Rightarrow d_j \geq 0$

$\boxed{y \in N_d \setminus r}$

pokud $d_{sj} < 0 \Rightarrow$
 \Rightarrow pouze def indexu \leq

$$\frac{d_j^*}{|d_{sj}|} > \frac{\tilde{d}_s^*}{|d_{sr}|} \Rightarrow \frac{\tilde{d}_s^*}{d_{sj}} < \frac{\tilde{d}_s^*}{d_{sr}} \Rightarrow$$

$$\Rightarrow \tilde{d}_s^* > \frac{\tilde{d}_s^* \cdot d_{sj}}{d_{sr}} \Rightarrow \tilde{d}_s^* \geq 0$$

$$d_r^* = \frac{\tilde{d}_s^*}{-d_{sr}} \geq 0$$

Dobromacky je $(y, y')^* \in M_2'$.

Podle transf. vzorce je $d_{oo}^* = d_{oo} - \frac{d_r^* \cdot d_s^*}{d_{sr}} \leq d_{oo}$.

Poznámka:

Pokud nenásilna! degenerace ($\tilde{d}_s^* > 0$) $\Rightarrow \tilde{d}_s^* > 0 \Rightarrow d_{oo}^* < d_{oo}$ \otimes

Metoda je konečná - máme kou mnoho jiných báz řeš a používame Blandovo pravidlo

Pozn: Dualní SM se dá řešit i bez předpokladu $C^T \leq 0$

Kdy určitou použíl DSH?

$$\max c^T x ; M = \{ x \mid Ax \leq b, x \geq 0 \}$$

$$\begin{array}{c} c < 0 \\ \hline b < 0 \end{array} \quad \text{uvedlo'}$$

$$Ax + x' - u = b$$

(6)

28.03.2008

Celocíselné programování

Definice 1: Ulohu $\max_{x \in M} f(x)$, kde $f: \mathbb{R}^n \rightarrow \mathbb{R}$, $M \subset \mathbb{R}^n$

$$M = \{ x \in \mathbb{R}^n \mid g_j(x) \leq 0 \ (j=1, \dots, m), x_i \in \mathbb{Z}, i \in C \subseteq \{1, \dots, n\} \}$$

$g_j(x): \mathbb{R}^n \rightarrow \mathbb{R}$ má zároveň obecnou ulohu celocíselného programování.

Je-li $C = \{1, \dots, n\}$, potom máme cílovou ulohu, a je-li

$C \subseteq \{1, \dots, n\}$ a smíšenou ulohu.

Metody: 1) řešení maticového

(metody řezu)


2) Kombinatorické

- Branch and Bound

3) Přibližné metody

pro spec. problém // často se opakují ulohy

4) Speciální metody



Gomory



Definice 2: Ulohu $\max_{M_C} c^T x$; $c \in \mathbb{R}^n$; $M_C = \{ x \in \mathbb{R}^n \mid Ax \leq b, x \geq 0, x_i \in \mathbb{Z}, i \in C, C \subseteq \{1, \dots, n\}, A \in \mathbb{R}^{m \times n}, b \in \mathbb{R}^m \}$

má zároveň ulohu lineárního cílového (pokud $C = \{1, \dots, n+m\}$)

nebo smíšeného (pokud $C \subseteq \{1, \dots, n+m\}$) celocíselného programování.

Poznámka: Nerovnosti $Ax \leq b$ nahradíme $Ax + x' = b$, $x' \geq 0$,

$$x' = (x_{n+1}, \dots, x_{n+m}).$$

Definice 3: Ulohu $\max_M c^T x$, kde $M = \{ x \mid Ax \leq b, x \geq 0 \}$ má zároveň spojitu ulohu přířazenou k (1).

Poznámka: Budeme řešit ekvivalentní ulohu k (2)

$$(2') \max_{M'} c^T x, M' = \{ (x, x') \in \mathbb{R}^{n+m} \mid Ax + x' = b, x, x' \geq 0 \}$$

Mýšlenka 1. Gomoryho alg.

(17)

Září číslova u'loha lin. el. loc. prg.

Nechť v n -sejm broku alg. máme opt. řešení $(x^*, x'^*)^*$ u'lohy (2').


Jestliže $(x^*, x'^*)^* \in M'_C$ potom je x^* opt. řešení (1).

Jestliže $(x^*, x'^*)^* \notin M'_C$, zavedeme více množiny M'_C .

Nechť $x_k^* \notin M'_C$

$$z M' \Rightarrow x_k = x_k^* - \sum_{j \in N} d_{kj} x_j, \text{ kde } d_{kj} \text{ a } x_k^* = d_{k0}$$

jsou hodnoty \approx poslední. Ta budou $(k - k')$ rádek.



Zavedeme-li označení pro $b \in \mathbb{R}$ $b = [b] + \boxed{b}$,

potom $[b]$ nejbližší nížší celé číslo k b a \boxed{b} je zbytek. \checkmark

$$\text{Tedy } 0 \leq \boxed{b} < 1, \text{ a dále } x_k = [\underline{d_{k0}}] + \boxed{\underline{d_{kj}}} + \sum_{j=1}^{k-1} \boxed{d_{kj}} x_j$$

$$- \sum [\underline{d_{kj}}] x_j - \sum \boxed{\underline{d_{kj}}} x_j$$

$$\text{Veta 1: Množ. } R = \left\{ (x, x') \in \mathbb{R}^{m+n} \mid -[\underline{d_{k0}}] + \sum_{j=1}^{k-1} \boxed{\underline{d_{kj}}} x_j = 0 \right\},$$

je sečnovu množinou s vlastností:

$$(x, x')^* \in H^-, M'_C \subset \overline{H}^+, \text{ kde}$$

$$H^- = \left\{ (x, x') \in \mathbb{R}^{m+n} \mid -[\underline{d_{k0}}] + \sum_{j=1}^{k-1} \boxed{\underline{d_{kj}}} x_j \leq 0 \right\},$$

$$\overline{H}^+ = \left\{ \dots \geq 0 \right\}.$$

$$\text{Dle: Pro } (x, x')^* \text{ platí } (x, x')_B^* = \underline{d_{k0}}, (x, x')_N^* = 0$$

Tedy po dosazení $(x, x')^*$:

$$-[\underline{d_{k0}}] + \sum_{j=1}^{k-1} \boxed{\underline{d_{kj}}} \cdot 0 \leq 0 \Rightarrow (x, x')^* \in H^-$$

Zvolíme lib. $(x, x') \in M'_C \Rightarrow$ pro k-tou rovnici

$$x_k = d_{0k} - \sum_{\substack{j \in N \\ \text{crystal}}} \underbrace{d_{kj}}_{\in \mathbb{Z}} x_j = [d_{0k}] + \boxed{d_{0k}} - \sum_{j \in N} [d_{kj}] x_j - \sum_{j \in N} \boxed{[d_{kj}]} x_j \quad (18)$$

$$\underbrace{-[d_{0k}] + \sum_{j \in N} [d_{kj}] x_j}_{\in \mathbb{Z}} = -x_k + [d_{0k}] - \sum_{j \in N} [d_{kj}] x_j \quad \in \mathbb{Z}$$

\exists Pokracujeme dále řešením spojité užlohy $\max_{M^1 \cap H^+} C^T x$

\circ když některá $d_{kj} \in \mathbb{Z}$ (ale $d_{0k} \notin \mathbb{Z}$) \Rightarrow možná řeš. $= \emptyset$

Pro důkaz používáme 1. Gomoryho alg. budeme předp. $C^T x \in \mathbb{Z}, x \in M$,
 $\bullet C \in \mathbb{Q}$ je se převole na výsobením do \mathbb{Z}) jednoznačné

dále M je omezená,

dále budeme pracovat s lexicograficky optimálním (l -optimálním)
 řešením jednoznačných užloh $\max_{M^1 \cap H_1^+ \cap \dots \cap H_m^+} C^T x$

Poslední předp. je: $M_c \neq \emptyset$

$$x = (0, \dots, 0, \underline{1}, -100)$$

Lexikografie:

Definice 4: $x \in \mathbb{R}^n$ nazveme l -kladný, jestliže platí $x_k > 0$,

$k = \min \{ i = 1, \dots, n \mid x_i \neq 0 \}$; označme $x \succ 0$.
 x je l -nezáporný, jestliže je $x = 0$ nebo $x \succ 0$.

Def 5: Říkáme, že x je l -nežádoucí než y ($x, y \in \mathbb{R}^n$) jestliže $x - y \succ 0$.

Ozn: $C^T x \equiv \max_{M^1} x_0 ; x \in M^1$ a sedly $(x, x') \in M^1$

Přesloužíme pro nás tak, aby x_1 byla nejdůležitější $\Rightarrow x'_i, i \in \{1, \dots, n\}$,
 pak x_2, \dots

Věta: Je-li M omezená a $M_{opt} \neq \emptyset$, potom $\exists l$ -opt. řeš. užlohy $\max_M C^T x$.

Dk: Vymeďte $M_{opt} = \{x \in M \mid x_j = 0 ; j \in J_0\}$,

$$J_0 = \{j \in N \mid c_j - x_j < 0\}$$

↳ všechny posl. tabuły

a $M_{opt} \neq \emptyset$, omezená \Rightarrow je konvexním polyedrem.

Je-li $M_{opt} \neq \{x^{opt}\}$, potom pro $x \in M_{opt}$ řešíme užlohu

$\max x_1$. To ex. a oz. ho M_{opt}^1 .

$$M_{opt}^1$$

Pokud $M_{\text{opt}}^1 = \{x^{\text{opt}}\}$, potom je l-opt. řeš. v opačném
případě řeš. $\max_{M_{\text{opt}}^1} x_2$ atd. \rightarrow konec (\Rightarrow kon. # proměnných)

dualní simplex

Poznámka:

X nezávislé		0
x_0	-c	0
x_1		
	-E	0
x_n		
	A	b
x_{m+n}		

Výchozí tabulka:

$$x' = \mathbb{L} \quad \text{závislé proměnné}$$

$$x = 0 \quad \text{nezávislé -a}$$

$$x' = \mathbb{L} - A x$$

$$x = 0 - (-x) \quad \text{Id}$$

$$c^T x = 0 - (-c^T x)$$

Předp. $c < 0$.

(7)

04.04.2008

l-metoda (lexikografická dualní metoda)

$(x_{m+1}, \dots, x_{m+m})$

Řešení úlohy $\max c^T x$, $M^1 = \{(x, x') \in \mathbb{R}^{m+n} \mid Ax + x' = b, x, x' \geq 0\}$, $A \in \mathbb{R}^{m \times n}$

$$b \in \mathbb{R}^m, c \in \mathbb{R}^n.$$

R_1	\dots	R_N	R_0
		-c	0
x_0			
x_1		-E	0
x_{m+n}			
x_{m+1}			
x_{m+n}		A	b

$$x = 0 - (-x)$$

Výchozí l-tabulka:

$$c^T x = x_0$$

$$b \in \mathbb{R}^m, c \in \mathbb{R}^n.$$

pozn: l-tabulka se líší od tabulky DSM jen přehozem, t.j. posl. řádku na 1. řádek a přidáním $x = 0 - (-x)$ budou platit 1. a 2. věta DSM.

Ozn: sloupec l-tabulky jako R_j , $j \in N$ a posl. sl. jako R_0 .

Def: L-tabulku nazýváme l-normální, pokud platí $\sum R_j = 0$


$$j \in N.$$

nezávislé

Pozn: Výchozí l-sabulka je vzhledem k předp. C ≤ 0 l-normální.

Věta: Právopisné 'nedegerovane' baz. řešení je l-optimalní právě tehdy, je-li jinou preslušnou l-sabulku l-normální.

Důkaz: V obecném kroku l-metody máme sabulku



↑ L metoda odstranění degenerace (cyklus) $\epsilon > 0$

Po dle 1.V DSM máme opt. řeš. zadání užlohy.

Další opt. řešení (pokud existují) dostaneme sabulky s pivodem lebodným

Pro libovolný pivot $d_{nr} > 0$ by ~~bylo~~ po transf. tabulky platilo

$$R'_0 = R_0 - \frac{R_n \cdot d_{n0}^{-1}}{d_{nr}^{-1}}$$

a) Je-li l-sabulka l-normální $\Rightarrow R'_0 \neq R_0 \Rightarrow$ l-opt. řeš. $(x_0, x) = d_0$

b) Je-li $(x_0, x) = d_0$ l-opt. řeš., pak každé jiné opt. řeš. je l-normální

$$R'_0 = R_0 - \frac{R_n \cdot d_{n0}^{-1}}{d_{nr}^{-1}} \neq R_0 \Rightarrow R_n > 0 \text{ pro lib. } r \quad \square$$

1. věta l-metody: Je-li v l-sabulce $d_0 = (d_0)_B > 0, (d_0)_N = 0$ a tabulka je l-normální, potom jsme získali l-opt. řešení zadání užlohy.

2. věta l-metody: Plynou z 1 věty DSM a Věty *

2. věta l-metody: Ex- li v l-sabulce řádek s taky, že $d_{n0} < 0, d_{nj} \geq 0, j \in N$, potom neexistuje řešení zadání užlohy.

Důkaz: Plynou z 2 věty DSM

3. věta l-metody: Nejsou-li splněny předpoklady 1. ani 2. Vlny socií (21)
 potom $s = \min_{\text{def}} \left\{ i = 1, \dots, m+n \mid d_{se} < 0 \right\}$,

$$l \neq \text{def} : \min_{j \in N} \left\{ \frac{R_j}{|d_{sj}|} \right\} = \frac{R_e}{|d_{se}|}$$

jednoznačné
urč. díky ex - E matici

a provedeme transformaci l-tabulky s pivotelem

$d_{se} < 0$. Dostaneme opět l-normální tabulku.

$$\text{dále } R'_e = \frac{R_e}{-d_{se}} \neq \infty$$

$$d_{sj} \geq 0 \Rightarrow R'_j \neq \infty$$

$$\begin{aligned} j \in N \setminus \{s\} \\ R'_j = R_j - \frac{R_e \cdot d_{sj}}{d_{se} < 0} \end{aligned}$$

$$\begin{aligned} d_{sj} < 0 \Rightarrow \text{Podle def } l \Rightarrow \frac{R_e}{|d_{se}|} < \frac{R_j}{|d_{sj}|} \\ \Rightarrow \frac{R_e}{d_{se}} > \frac{R_j}{d_{sj}} \Rightarrow R_j < \frac{R_e}{d_{se}} \cdot d_{sj} \\ \Rightarrow R'_j < 0 \Rightarrow \text{opět l-normální tabulka.} \end{aligned}$$

$$\text{Dále } R'_o = R_o - \frac{R_e \cdot d_{os}}{d_{se} < 0} < R_o. \quad \square$$

Pozn: jediný rozdíl oproti DSM je, že když máme řádek na hraniční

$$\begin{array}{ccccccc} 0 & \dots & 0 & -1 & 0 & \dots & 0 | 0 \\ \downarrow & & & & & & \\ R_o & & & & & & \end{array}$$

Pozn: l-metoda je konečná, protože báckých řešení je pouze konečný počet a memusíme se mazat ohledem k $R'_o < R_o$.

LAlg ->

1. Gomoryho alg.

Rěšení cílovou užlohu

$$\max_{M_c^1} C^T x, M_c^1 = \left\{ (x, x') \in \mathbb{R}^{m+n} \mid Ax + x' = b, x, x' \geq 0, x_1, \dots, x_m \in \mathbb{Z} \right\}$$

Předp: 1) $C^T x = x_0 \in \mathbb{Z}$;2) M je omezená;

3) v zadání kroků mohou nastat degenerace;

4) $C < 0$

1. krok: l-metodou řešíme užlohu

$$\max_{M^1} C^T x$$

n-tý krok: l-metodou řešíme užlohu

$$(n) \max_{M^1 \cap H_1^+ \cap H_2^+ \cap \dots \cap H_{n-1}^+} C^T x$$

@ neex. rěš. užlohy (n) $\Rightarrow M^1 \cap H_1^+ \cap \dots \cap H_{n-1}^+ = \emptyset \Rightarrow M_c^1 = \emptyset$, konc.@ \exists l-opt. rěš. $(x, x')^{\text{opt}} \in M_c^1 \Rightarrow$ máme opt. rěš. zadání užlohy@ \exists l-opt. rěš. $(x, x')^{\text{opt}} \notin M_c^1$

$$\text{ozn.: } h = \min \{ i \in \{0, 1, \dots, m+n\} \mid d_{ij} \notin \mathbb{Z} \}$$

z posl. tabulkou mybereme h-ty rádek

x_k	dej	deo
-------	-----	-----

a utváříme řeš.

$$-d_{k0} + \sum_{j \in N} d_{kj} x_j \geq 0 \quad \begin{matrix} -x_{m+n+r+1} \\ \nearrow \\ \searrow \end{matrix}$$

 H_n^+

což připomínáme na tvor

$$x_{m+n+r+1} = -d_{k0} + \sum_{j \in N} d_{kj} x_j \quad a \quad k \text{ poslední!}$$

tabulce přidáme rádek jako poslední!

$x_{m+n+r+1}$	[-dej]	[-deo]
---------------	--------	--------


a řešíme tedy úlohu

$$\max_{\mathbf{x}} \mathbf{c}^T \mathbf{x}$$

$$M \cap H_1^+ \cap \dots \cap H_{n-1}^+ \cap H_n^+$$

Zřejmě posl. řádek je klicový

l-metodou



Po jedné' transf. tabulky ~~našel by~~ přidání posl. řádku
vyhodit $\Rightarrow r := r+1 \rightarrow r$ -tý krok.

Pozn: Za uvedených předp. je 1. Gomariho alg. konečný.

(8.)


M. 04. 2008

Komb. metod CLP

Metoda Branch & Bound Landa a Doiga

Réšíme $\max_{\mathbf{x}} \mathbf{c}^T \mathbf{x}$ $M_C = \{ \mathbf{x} \in \mathbb{R}^n | A \mathbf{x} \leq \mathbf{b}, \mathbf{x} \geq 0, \forall x_i \in \mathbb{Z}, i \in C \subseteq \{1, \dots, n\} \}$

$$A \in \mathbb{R}^{m \times n} \quad h(A) = m$$



1. krok - řešíme úlohu spojitoru $\max_{\mathbf{x}} \mathbf{c}^T \mathbf{x}$ na M

není řeš. $M = \emptyset \Rightarrow M_C = \emptyset$
konc.

není řeš., protože $\mathbf{c}^T \mathbf{x}$
shora neomezena na M
 \Rightarrow nelze je řešit metoda
výk. s.
 \Rightarrow Předpokladáme M omezená

existuje opt. řeš. $\mathbf{x}^* \in M_C \Rightarrow$ máme řeš.
 $\mathbf{x}^* \in M_C$, pak jdeme na krok 2.

2. krok určíme $k = \min \{ \alpha \in C | x_{\alpha}^{\text{opt}} \notin \mathbb{Z} \}$

definujme $M_1 = \{ \mathbf{x} \in M | x_k \leq \lfloor x_{\alpha}^{\text{opt}} \rfloor \}$ \Rightarrow konvexní polyhedr
 $M_2 = \{ \mathbf{x} \in M | x_k \geq \lfloor x_{\alpha}^{\text{opt}} \rfloor + 1 \}$ \Rightarrow přídání 1 lineární
neovnosnosti

Réšíme 2 úlohy @ $\max_{M_1} \mathbf{c}^T \mathbf{x}$; $\max_{M_2} \mathbf{c}^T \mathbf{x}$.

ZÁKLADY OPTIMALIZACE

11.4.2008

(20) (1)
(24)

METÓDA BRANCH AND BOUND LANDA A DOIGA

Riešenie $\max_{M_C} C^T X$, $M_C = \{X \in \mathbb{R}^n \mid Ax = b, X \geq 0, X_d \in \mathbb{Z}, d \in C \subseteq \{1, \dots, n\}\}$,
 $1 \leq m \leq n$, $A \in \mathbb{R}^{m \times n}$, $b(A) = m$.

1. krok: Riešme náhodnú spojistiu $\max_M C^T X$

nesexistuje riešenie, keďže $M = \emptyset \Rightarrow M_C = \emptyset \Rightarrow$ koniec

existuje riešenie, pretože $C^T X$ zhore neobmedzené na $M \rightarrow$

\rightarrow nemôžeme súčasne metódu použiť \Rightarrow Budeme využívať, keďže M_C je obm.

existuje $X^{opt} \in M_C \Rightarrow$ máme riešenie zadanej úlohy. Koniec

existuje $X^{opt} \notin M_C$, potom ideme na krok 2.

2. krok:

Určime $k = \min \{d \in C \mid X_d^{opt} \notin \mathbb{Z}\}$

Definujeme $M_1 = \{X \in M \mid X_k \leq \lfloor X_k^{opt} \rfloor\}$

$M_2 = \{X \in M \mid X_k \geq \lceil X_k^{opt} \rceil + 1\}$ konvenčné polyédery

Riešenie 2 úloh: ① $\max_{M_1} C^T X$, ② $\max_{M_2} C^T X$

a) $M_1 = \emptyset$ b) $M_2 = \emptyset \Rightarrow M_C = \emptyset \Rightarrow$ nesexistuje riešenie. Koniec.

c) $\exists X^2$ opt. riešenie ① vložíme do ② $X^2 \in M_C \Rightarrow X^2$ je opt. Koniec

d) $\exists X^2 \notin M_C$. Potom definime M_2 . $M = M_2$ a krok 2.

e) $\exists X^1$ opt. riešenie úlohy ① a) $M_2 = \emptyset \Rightarrow X^1$ je opt. Koniec

b) $\exists X^2 \in M_C$. Ak $C^T X^1 \geq C^T X^2 \Rightarrow X^1$ je opt. Koniec
 Ak $C^T X^1 < C^T X^2$, potom vložíme $X^1, C^T X^1$ a definime M_2 , $M = M_2$ a krok 2.

f) $\exists X^1$ úlohy ② vložíme a) $M_2 = \emptyset \Rightarrow M = M_1$ a krok 2.

b) $\exists X^2 \in M_C$, $C^T X^1 \leq C^T X^2 \Rightarrow X^2$ je opt. Koniec
 $C^T X^1 > C^T X^2 \Rightarrow$ vložíme $X^2, C^T X^2$, $M = M_1 \rightarrow$ 2. krok

gr) $\exists x^2 \notin M_C$, resp. jiné $M = M_1, M = M_2$ až krok.

Odpověď se nově říká, ak $|C| = 2, 3$. Známe ak $C = \{1, \dots, n\}$, potom je lepší použít metodu sečných množin.

Pozn:

$x_{opt.}$

x_k	x_B	x_N	
			$d_{0k} \notin \mathbb{Z}$
x_B	E	D	d_B
kriteriálny riadok			

$$x_k^{opt.} = d_{0k} \notin \mathbb{Z}$$

$$\begin{aligned} k\text{-tý riadok} &= x_k = d_{0k} - \sum_{j \in N} d_{kj} x_j \\ x_k + \xi &= [d_{0k}] \end{aligned} \quad \Rightarrow \quad \left. \begin{aligned} \xi &= [d_{0k}] - d_{0k} + \sum_{j \in N} d_{kj} x_j \\ &\geq 0 \end{aligned} \right\}$$

Menší kritický riadok je posledný kritický riadok

$$u = -[d_{0k}] + d_{0k} - \xi - \sum_N d_{kj} x_j$$

x_B	x_N	u	ξ
E	D	0 0	0
		0 0	0
d_{kj}	1 0	$d_{0k} - [d_{0k}]$	

PARAMETRICKÉ PROGRAMOVANIE

Definícia:

Všeobecnou výzvou parametrického programovania je maximizovať:

- (1) $\min_{\substack{x \in M(\nu) \\ \nu \in \mathbb{R}^m}} F(x, \nu)$, kde $F(x, \nu): \mathbb{R}^n \times \mathbb{R}^m \rightarrow \mathbb{R}$, $M(\nu) \subset \mathbb{R}^n$ je kódom, $\nu \in \mathbb{R}^m$ je vektorem parametru $\nu \in \mathbb{R}^m$

Znázornit ν , ν maximizuje parametre.

Definícia 1: mohy param. prop. (1)

Oborom riešiteľnosti rozumeme

$$\mathcal{A}_{\lambda, \nu} = \{(x, \nu) \in \mathbb{R}^{I+m} \mid (1) má rieš. \}$$

Definícia 2:

ak je x^0 optimálne riešenie mohy (1) pre párnej volbe λ^0, ν^0 ,
potom oborom stability riešenia x^0 rozumeme

$$\mathcal{A}_{\lambda^0, \nu^0} = \{(x, \nu) \in \mathbb{R}^{I+m} \mid \min_{x \in M(\nu)} F(x, \lambda) = F_{\nu}(x^0, \lambda)\}.$$

Definícia 3:

Funkciou riešiteľnosti mohy (1) rozumeme

$$Y(\lambda, \nu) = \min_{x \in M(\nu)} F(x, \lambda) \quad | \quad (\lambda, \nu) \in \mathcal{A}_{\lambda, \nu}.$$

Definícia I 1) jednoparametrické mohy

2) viacparametrické mohy

II 1) lineárne mohy

2) ~~lineárne~~ nelineárne mohy

ÚLOHA LINEÁRNEHO JEDNOPARAMETRICKÉHO PROGRAMOVANIA

S PARAMETROM V CIEĽOVEJ FUNKCII'

$$(2) \min_{\lambda} (c + \lambda c')^T x, \quad \lambda \in \mathbb{R}, \quad c, c' \in \mathbb{R}^n, \quad M = \{x \mid Ax = b, x \geq 0\}, \quad A \in \mathbb{R}^{m \times n}, \quad b \in \mathbb{R}^m$$



$$M \neq \emptyset, \quad 1 \leq m < n, \quad \text{rank}(A) = m$$

Myslenka: obor možností za riadi počet oboru stability.

(dúsme)


$\lambda = 1$ - prie

a mazne $(c + \lambda c')^T x$ súčasť do dosiahnutia
rovnobežky s pravidlami hranami



a tím dosáhne všechny obory stabilitu a může přípusťte' λ

(26)



(9)

1. Věta LAPP

Jestliže pro první $\lambda_0 \in \mathbb{R}$ ex. opt. řešení x^* ulohy (2), potom
 $\exists \underline{\lambda}_1, \bar{\lambda}_1, \underline{\lambda}_1 \leq \bar{\lambda}_1$ tak, že

1) pro $\lambda \in (\underline{\lambda}_1, \bar{\lambda}_1)$ existuje opt. řeš. ulohy (2) stále x^*

2) $\lambda_0 \in (\underline{\lambda}_1, \bar{\lambda}_1)$

3) nemá-li x^* degenerované, potom jmenem získali obor stabilitu řešení písaný x^*

Důkaz:

Pro první λ_0 máme ulohu LP a její řešení SM. Poslední tabulka:

$$\begin{matrix} c_B - \lambda_0 c'_B & c_N - \lambda_0 c'_N \\ x_B & x_N \end{matrix}$$

x_B	E	D	d_0	$\rightarrow \sigma$
σ				

$$(c_N + \lambda_0 c'_N) - (c_B + \lambda_0 c'_{NB})^T D \geq 0$$

Počle AV.SM $\Rightarrow \{ \lambda | (c_N - \lambda c'_N) - (c_B - \lambda c'_B)^T D \geq 0 \}$ je nato řešení bez. příp. (d_0, σ) optimální.

$$\text{Po úpravě } \underbrace{c_N - c_B^T D}_{\mu} + \lambda \underbrace{(c_N^T - c_B^T D)}_{v} = \mu + \lambda v.$$

$$\begin{aligned} \text{Oznacme: } I_1 &= \{ \alpha \in N \mid v_\alpha > 0 \} \\ I_2 &= \{ \alpha \in N \mid v_\alpha < 0 \} \\ I_3 &= \{ \alpha \in N \mid v_\alpha = 0 \} \end{aligned} \quad \left\{ \begin{array}{l} I_1 \cup I_2 \cup I_3 = N \\ I_1 \cap I_2 = \emptyset \end{array} \right.$$

$$\Rightarrow \text{pro } \alpha \in I_1 \Rightarrow \lambda \geq -\frac{u_\alpha}{v_\alpha}$$

$$\text{pro } \alpha \in I_2 \Rightarrow \lambda \leq -\frac{u_\alpha}{v_\alpha} \Rightarrow \lambda \in \left(\sup_{\alpha \in I_1} \left\{ -\frac{u_\alpha}{v_\alpha} \right\}; \inf_{\alpha \in I_2} \left\{ -\frac{u_\alpha}{v_\alpha} \right\} \right)$$

$$\underline{\lambda}_1 = \sup_{\alpha \in I_1} \left\{ -\frac{u_\alpha}{v_\alpha} \right\} \quad \overline{\lambda}_1 = \inf_{\alpha \in I_2} \left\{ -\frac{u_\alpha}{v_\alpha} \right\}$$

o osobní 'řežíme'

Poznámka: V případě degenerace x^* dostaneme pouze část oboru stability. K důkazu se ϵ -modifikovaná úloha.

Umluva: Předp. nádále, že při výpočtu SM nikdy nenastane degenerace.

Důsledek 1: Obory stability jsou konečně uzavřené množiny a jejich pouze konečný počet.

($\langle \underline{\lambda}_i, \overline{\lambda}_i \rangle$ jsou jednoznačně přiřazeny vrcholům $x^i \in M$, kterých je pouze konečný počet)

$\langle \underline{\lambda}_i, \overline{\lambda}_i \rangle$ jsou $\begin{cases} \text{uzavřené 'úsečky'} \\ \text{uzavřené 'polopřímky'} \end{cases}$

2. Věta L1PP:

ještě pro první $\lambda_0 \in \mathbb{R}$ neex. řešení' u'lohy (2) a $M \neq \emptyset$, potom $\exists \alpha$ otevřený interval J tak, že:

1) pro $j \in J$ neex. řešení' u'lohy (2).

2) $\lambda_0 \in J$.

Důkaz: Podle SM dojdeme k tabulce:

x_B	x_B	x_U	
E	D	$d_0 > 0$	
0	$\mu + \lambda_0 v_0$	≤ 0	≤ 0

2. Věta SM $\Rightarrow \exists j \in N$ tak, že

$$\mu_j + \lambda_0 v_j < 0 \quad d_{ij} \leq 0, \quad i \in B$$

Protože $\{d_{ij}\}, \quad i \in B$ nezávisí na λ .

$\Rightarrow \{ \lambda \mid \mu_j + \lambda v_j < 0 \}$ neex. řešení' působné' u'lohy (plňte r. 2. věty SM)

Naslane 1 a násled. možnosti:

$$a) v_j > 0 \Rightarrow \lambda < -\frac{\mu_j}{v_j} \Rightarrow J = (-\infty, -\frac{\mu_j}{v_j})$$

$$b) v_j < 0 \Rightarrow \lambda > -\frac{\mu_j}{v_j} \Rightarrow J = (-\frac{\mu_j}{v_j}, \infty)$$

$$c) v_j = 0 \Rightarrow \mu_j < 0 \Rightarrow J = \mathbb{R}$$

∇ nej' do
o nej' leh
největší' možn
interval

Uvádění 2:

Obeor řešitelnosti užloby (2) $A = \{\lambda \in \mathbb{R} \mid (2) \text{ má řešení}\}$ je konvexní množina,
pro kdežto platí $A = \bigcup_{i \in P} \langle \underline{\lambda}_i, \bar{\lambda}_i \rangle$, kde P je množina indexů vrcholů M .

Důkaz:

" \Rightarrow : Zvolme $\lambda \in A$ které $\stackrel{1. LP}{\Rightarrow}$ musí být řeš. množina \sim aspoň 1 vrchol $M \Rightarrow$
 $\Rightarrow \exists i \mid \lambda \in \langle \underline{\lambda}_i, \bar{\lambda}_i \rangle \Rightarrow \lambda \in \bigcup_{i \in P} \langle \underline{\lambda}_i, \bar{\lambda}_i \rangle$

" \Leftarrow : Zvolme $\lambda \in \bigcup_{i \in P} \langle \underline{\lambda}_i, \bar{\lambda}_i \rangle \Rightarrow \exists i \mid \lambda \in \langle \underline{\lambda}_i, \bar{\lambda}_i \rangle$ průčinný opt. řeš. $\neq \star^i$ k λ_i .
řešení (2) existuje $\Rightarrow \lambda \in A$.

Konverzita:

Zvolme $\lambda_1, \lambda_2 \in A$, def $\lambda_3 = \alpha \lambda_1 + \beta \lambda_2$, $\alpha + \beta = 1$, $\alpha, \beta \geq 0$.

Když $\lambda_3 \notin A \Rightarrow$ pro $\lambda_3 \not\models$ opt. řeš. (2) $\stackrel{2VL1PP}{\Rightarrow} \exists J \in \mathbb{Z}$ otevřený interval,
kde řešení také neexistuje. Potom ale λ_1 nebo λ_2 do J patří a to je spor.

Neplatnost: \exists jednotlivé konkrétní počtu nesouhlasných množin je neplatná množina.

3VL1PP: Nech X^* je optimální řešení v oboru stabilitky $\langle \underline{\lambda}_1, \bar{\lambda}_1 \rangle$.

Jestliže $\bar{\lambda}_1 < 1VL1PP$ je konečné, potom pro $\lambda > \bar{\lambda}_1$ nastane jedna z možností:
a) pro $\lambda > \bar{\lambda}_1$ neexistuje opt. řešení (2)

b) $\exists \star^2$ sousední vrchol M k vrcholu X^* a k množině $\langle \underline{\lambda}_2, \bar{\lambda}_2 \rangle$ tak,
že pro $\lambda \in \langle \underline{\lambda}_2, \bar{\lambda}_2 \rangle$ existuje opt. řeš. \star^2 a navíc platí $\bar{\lambda}_1 = \underline{\lambda}_2$.

Pozn: Analogická věta platí i obráceně pro $\underline{\lambda}_1$.

Def: Funkce $\Psi(\lambda) = \min_M (\mathbf{c} - \lambda \mathbf{c}')^T \mathbf{x}$, $\lambda \in A$ se nazývá řešitelností (2).

4. Věta L1PP: Funkce $\Psi(\lambda)$ je na A po částečně lineární a spojita a konkávní.

Důkaz: Nad každým $\langle \underline{\lambda}_i, \bar{\lambda}_i \rangle$ platí $\Psi(\lambda) = (\mathbf{c} - \lambda \mathbf{c}')^T \mathbf{x}^i$ $\forall i$ - lineární!

Protože $A = \bigcup \langle \underline{\lambda}_i, \bar{\lambda}_i \rangle$ a podle 3VL1PP je $\bar{\lambda}_i = \underline{\lambda}_{i+1}$ $\forall i \rightarrow$


$\Rightarrow \Psi$ je po částečně lineární a spojita nad A .

Konverzita:

Zvolme $\lambda_1, \lambda_2 \in A$ a $\lambda_3 = \alpha \lambda_1 + \beta \lambda_2$, $\alpha + \beta = 1$, $\alpha, \beta \geq 0$

$$\Psi(\lambda_3) = \min_M ((\mathbf{c} + \beta \mathbf{c}')^T \mathbf{x} + \alpha (\lambda_1 + \beta \lambda_2) \mathbf{c}'^T \mathbf{x}) \geq \alpha \min_M (\mathbf{c} + \lambda_1 \mathbf{c}')^T \mathbf{x} +$$

$$+ \beta \min_M (\mathbf{c} + \lambda_2 \mathbf{c}')^T \mathbf{x} = \alpha \Psi(\lambda_1) + \beta \Psi(\lambda_2).$$



Poznámka: Pokud $\lambda \in I$, kde I je první omezený uzavřený interval, potom

$\min_{M \times I} (\mathbf{c} + \lambda \mathbf{c}')^T \mathbf{x}$ existuje a dosáhne λ_1, \mathbf{x}^* opt.

$$I = \langle \lambda^0, \lambda^{00} \rangle : \left. \begin{aligned} &\min_M (\mathbf{c} + \lambda^0 \mathbf{c}')^T \mathbf{x} \\ &\min_M (\mathbf{c} + \lambda^{00} \mathbf{c}')^T \mathbf{x} \end{aligned} \right\} \text{minima z funkcionálů} \\ \text{odstín je optimální}$$

Pozor!: Když jde o lineárního parametrického programování neexistuje řešení vždy.

Nelivnámi programování - výhledy (konvexní, obecnější konvexní) (28)

Věta 1: Množina $M = \{x \in \mathbb{R}^m \mid g_j(x) \leq 0, j=1, \dots, m\}$, $g_j: \mathbb{R}^m \rightarrow \mathbb{R}$ konvexní, je konvexní.

Dk: $x^1, x^2 \in M$, $x^3 = \alpha x^1 + \beta x^2$, $\alpha + \beta = 1$, $\alpha, \beta \geq 0$

$$\forall j \quad g_j(x^3) = g_j(\alpha x^1 + \beta x^2) \leq \alpha g_j(x^1) + \beta g_j(x^2) \leq 0 \Rightarrow x^3 \in M$$


Věta 2: Každé lokální minimum konvexní funkce je minimum globální!

Platí v \mathbb{R}^m někdo lib. konvexní množiny $M \subset \mathbb{R}^m$.

Důkaz: Nechť x^* je lok. min. $\Rightarrow \exists \delta(x^*, \varepsilon)$

tedy, že pro $x \in \delta(x^*, \varepsilon) \cap M$ platí

$$f(x) \geq f(x^*)$$



Pro důkaz sporém předp. že $\exists x' \in M$ tak, že $f(x') < f(x^*)$.

z konvexity $M \Rightarrow x = \alpha x^1 + \beta x^* \in M \quad \alpha + \beta = 1, \alpha, \beta \geq 0$.

z konvexity $f \Rightarrow f(x) \leq \alpha f(x^1) + \beta f(x^*) < (\alpha + \beta) f(x^*)$ pro $\alpha, \beta > 0$.

Pro $x = \alpha x^1 + \beta x^*, x \in \delta(x^*, \varepsilon)$ ale platí $f(x) \geq f(x^*)$

(10)

25.04.2008

Lemma: Funkce $F(x)$, kde má 1. parc. derivace na otevřené konvexní m. M

(2) je konvexní \Leftrightarrow platí:

$$F(x^2) - F(x^1) \geq \nabla F(x^1)^T (x^2 - x^1), \quad \forall x^1, x^2 \in M.$$

Věta 3: Je-li $f(x) \in C^2$ na otevřené konvexní množině M , potom je konvexní na $M \Leftrightarrow \nabla^2 f(x) = H(x) = \begin{pmatrix} \frac{\partial^2 f}{\partial x_1^2}, & \dots, & \frac{\partial^2 f}{\partial x_1 \partial x_m} \\ \vdots, & \ddots, & \vdots \end{pmatrix}$ je pozitivně semi definitor.

Dk: Taylorova věda: $f(x^2) = f(x^1) + \nabla f(x^1)^T (x^2 - x^1) + \frac{1}{2} (x^2 - x^1)^T \nabla^2 f(x^1) + \textcircled{1} (x^2 - x^1)^T (x^2 - x^1) \quad (1)$

$$\begin{aligned} 1) \quad f(x) \text{ je konvexní} \Leftrightarrow f(x) \geq f(x^1) + \nabla f(x^1)^T (x^2 - x^1) \stackrel{(1)}{\Rightarrow} \\ \rightarrow (x^2 - x^1)^T \nabla^2 f(x^1 + \textcircled{1}(x^2 - x^1)) (x^2 - x^1) \geq 0 \quad (2) \end{aligned}$$


Pro důkaz sporém, předp. že $\nabla^2 f(x)$ není poz. semi definitor na $M \Rightarrow$

$\Rightarrow \exists x^* \in M, V \neq 0$ tak, že $V^T \nabla^2 f(x^*) V < 0$.

Protože 2. parc. derivace jsou shodné $\Rightarrow \exists \delta(x^*, \varepsilon) \subset M$

tak, že $V^T \nabla^2 f(x) V < 0, \quad \forall x \in \delta(x^*, \varepsilon)$.

v $\delta(x^*, \varepsilon)$ $\exists x$ tak, že $V = P(x - x^*)$, $P > 0$ (dim $\delta(x^*, \varepsilon) > 1 \Rightarrow V \neq 0$)



Položim $\textcircled{3} \Rightarrow \rho^2 (\tilde{x} - x^*)^\top \nabla^2 f(x) (\tilde{x} - x^*) < 0$, což je spor s $\textcircled{2}$.
 Protože pro lib. $\Theta \in (0, 1)$ je $x \geq x^* + \Theta(\tilde{x} - x^*) \in \Gamma(x^* + \varepsilon)$, $\Rightarrow (\tilde{x} - x^*)^\top \nabla^2 f(x^* + \Theta(\tilde{x} - x^*))$
 $\nabla^2 f(x)$ pos. semidefinitní $x \in M \Rightarrow$ pro lib. $x^1, x^2 \in M$

$$(x^2 - x^1)^+$$

2

Zobecněné konvexní funkce

I. Základová značka konvexní def. abor.


Definice 2: Funkce $f(x)$ definovanou na konvexní množině M má značku

kvaž konvexní, jestliže pro lib. $x^1, x^2 \in M$ a $\lambda_1, \lambda_2 \geq 0$ $\lambda_1 + \lambda_2 = 1$,


$$\text{platí } f(\lambda_1 x^1 + \lambda_2 x^2) \leq \max \{ f(x^1), f(x^2) \}.$$

Funkce $f(x)$ je explicitně konvexní na M , je-li rovněž kvaž konvexní
 a dále platí pro lib. $x^1, x^2 \in M$ a $\lambda_1, \lambda_2 \geq 0$ $\lambda_1 + \lambda_2 = 1$, $f(x) \neq f(x^2) \Rightarrow$
 $\Rightarrow f(\lambda_1 x^1 + \lambda_2 x^2) < \max \{ f(x^1), f(x^2) \}$.

Př: expl. kvaž konvexní \Rightarrow když je uvedená líně se minimálně



kvaž konvexní



Výtažek: Platí na konvexní množině M , že f je konvexní $\Rightarrow f$ expl. kvaž konvexní
 $\Rightarrow f$ kvaž konvexní.

$$\text{Dk: } \forall x^1, x^2 \in M \quad \lambda_1, \lambda_2 \geq 0 \quad \lambda_1 + \lambda_2 = 0 \quad \xrightarrow{\text{konvexitá}} \quad f(\lambda_1 x^1 + \lambda_2 x^2) \leq \lambda_1 f(x^1) + \lambda_2 f(x^2) \leq$$

$$\leq \lambda_1 \max \{ f(x^1), f(x^2) \} + \lambda_2 \max \{ f(x^1), f(x^2) \} = \max \{ f(x^1), f(x^2) \}$$

$\overbrace{\text{expl. } \lambda_1, \lambda_2 \geq 0 \text{ a } f(x^1) \neq f(x^2)}$

expl. kvaž konvexní \Rightarrow kvaž konvexní!

Věta 5. Funkce $f(x)$ def. na konvex. množ. M je kvazi-konvexn' $\Leftrightarrow \forall d \in \mathbb{R}$ (29)
 platí, že $A_d = \{x \in M \mid f(x) \leq d\}$ je konvexní!

Dle, že A_d je konvexní! Zvolme $\lambda \in \mathbb{R}$ a $x^1, x^2 \in A_d$ lib. a uvažme $x = \lambda_1 x^1 + \lambda_2 x^2$
 $\lambda_1, \lambda_2 \geq 0, \lambda_1 + \lambda_2 = 1$. ? $x \in A_d$

Protože M je konvexní $\Rightarrow x \in M$

$$f(x) \leq \max(f(x^1), f(x^2)) \leq d \Rightarrow A_d \text{ je konvexní!}$$

2) A_∞ je konvexní $\forall d \in \mathbb{R}$. ~~Zvolme~~

Zvolme $x^1, x^2 \in M, \lambda_1, \lambda_2 \geq 0, \lambda_1 + \lambda_2 = 1$ a def. $x = \lambda_1 x^1 + \lambda_2 x^2$.

$$\max\{f(x^1), f(x^2)\} = d^0.$$

Platí $f(x^1) \leq d^0, f(x^2) \leq d^0 \rightarrow x^1, x^2 \in A_{d^0}$ - konvexní $\rightarrow x \in A_{d^0}$

$\Rightarrow x \in M \text{ a } f(x) \leq d^0 = \max\{f(x^1), f(x^2)\} \Rightarrow$ kvazi-konvexita f

Důsledek: Monotóna L = $\{x \in M \mid f_i(x) \leq b_i, (i=1, \dots, n)\}$, kde M je konvexní,
 $b_i \in \mathbb{R}$, f_i kvazi-konvexní na M $\forall i$, je konvexní!

Věta 6: Každé lok. minimum expl. kvazi-konvexní fce $f(x) \in \mathbb{R}^m$
 je absolutní!

Dle:  Uvažujme x^* jako lok. min $f(x) \in \mathbb{R}^n$.
 $\Rightarrow \exists O(x^*, \varepsilon)$ tak, že pro $\forall x \in O(x^*, \varepsilon)$ platí $f(x) \geq f(x^*)$.
 Pro spor předp., že x^* nemá globální abs. min. f $\Rightarrow \exists x^1: f(x^1) < f(x^*)$
 expl. pro $\forall x = \lambda_1 x^* + \lambda_2 x^1, \lambda_1, \lambda_2 \geq 0, \lambda_1 + \lambda_2 = 1$
 kvazi-konvexní
 $f(x) < f(x^*) = \max\{f(x^1), f(x^*)\}$. Pro $x \in O(x^*, \varepsilon)$ je

Poznámka: f je kvazi-konkavní $\Leftrightarrow -f$ je kvazi-konvexní!
 expl. $-u \quad \Leftrightarrow \quad$ expl. $-f$

$$\Rightarrow f(\lambda_1 x^1 + \lambda_2 x^2) \geq \min\{f(x^1), f(x^2)\}$$


II. M nemusí být konkávní, ale posadujme diferencovací buňku funkce.

Def 3: Funkce $f(x)$ definovanou v $x^* \in M$ nazýváme lok. pseudokonkávní, jestliže je v x^* diferencovatelná a

$$f(x) \leq f(x^*) \Rightarrow \nabla f(x^*)^T (x - x^*) \leq 0$$

$$f(x) < f(x^*) \Rightarrow \nabla f(x^*)^T (x - x^*) < 0, \quad x \in M$$

Prí:



Funkce $f(x)$ je pseudokonkávní na M , je-li lokačne pseudokonkávní pro $\forall x \in M$.

Def 4: Pro obecnou fci, která je v x^* diferencovatelná, nazýváme x^* učinným minimum $f(x)$ na M , jestliže platí $(x - x^*)^T \nabla f(x^*) \geq 0 \quad \forall x \in M$.

Věta 7: Každé učinné minimum pseudokonkávní funkce je minimem absolutní.

Dle: x^* učinné min $\Rightarrow (x - x^*)^T \nabla f(x^*) \geq 0, \quad x \in M$

Pro opor. předp., že není abs. $\Rightarrow \exists x^* \in M$ t.ž. $f(x^*) < f(x^*)$ pseudokonkávní
 $\Rightarrow (x^* - x^*)^T \nabla f(x^*) < 0 \Rightarrow \text{ly}$

Bušledek: Každý stacionární bod tj. x , pro které platí $\nabla f(x) = 0$ je abs. min. pseudokonkávní funkce.

Věta 8: Je-li M konkávní, potom pro diferencovatelnou funkci f na M platí: konkávní \Rightarrow pseudokonkávní (\Rightarrow expl. kvadratická \Rightarrow konz. konkav.)

Dle: Potřebné lemmatu (L): pro konv. fci $f(x^2) - f(x^1) \geq \nabla f(x^1)^T (x^2 - x^1)$
 $\geq f(x^2) \leq f(x^1) \Rightarrow \nabla f(x^1)^T (x^2 - x^1) \leq 0$

Poznámka: funkce $f(x)$ je pseudokonkávní, je-li $-f(x)$ pseudokonkávní.
Funkce $f(x)$ je pseudolineární, je-li současné pseudokonkávní & pseudokonkávní.

Pro pseudokonkávní

$$f(x) \geq f(x^*) \Rightarrow \nabla f(x^*)^T (x - x^*) \geq 0$$

>

Pro pseudolinéární

$$f(x) < f(x^*) \Rightarrow \nabla f(x^*)^\top (x - x^*) < 0$$

$$f(x) = f(x^*) \Rightarrow \nabla f(x^*)^\top (x - x^*) = 0$$

$$f(x) > f(x^*) \Rightarrow \nabla f(x^*)^\top (x - x^*) > 0$$

(11)

02.05.2008

(1) $\min_{\mathcal{M}} f(x)$; $\mathcal{M} = \{x \in N \mid g_i(x) \leq 0\}$ kde f, g_i - konvexní na $N \subseteq \mathbb{R}^m$, konvexní množina; $i = 1, \dots, m$

Úloha (1) je nárokovem konvexního programování.

Předp. mym', že f a g_i jsou spojité diferencovatelné na N .
(množina N otevřenou v \mathbb{R}^m) $\mathcal{M} \neq \emptyset \Rightarrow x^* \nabla f(x^*)$ adola omezené na \mathcal{M}

Kuhn-Tuckerovy podmínky

Def.: Lagrangeova funkce přiřazenou náloze (1):

$$\phi(x, \mu) = f(x) + \mu^\top g(x) \quad ; \quad \mu \geq 0, \quad x \in N$$

Definice: Řešení, kde (x^*, μ^*) splňuje Kuhn-Tuckerovy podmínky
(je K-T stacionární) ještě platí:

- (a) $\mu^* \geq 0, \quad x^* \in N$
- b) $\nabla_\mu \phi(x^*, \mu^*) \leq 0$
- c) $\nabla_x \phi(x^*, \mu^*) = 0$
- d) $\nabla_\mu \phi(x^*, \mu^*)^\top \mu^* = 0$

Přepis K-T na jejich geom. interpretaci:

$$\text{a)} \Rightarrow g_i(x^*) \leq 0 \stackrel{a)}{\Rightarrow} x^* \in \mathcal{M}$$

$$\text{a), b)} \Rightarrow g_i(x^*)^\top \mu^* = 0 \stackrel{a), b)}{\Rightarrow} \text{alespoň } 1 \text{ složka } g_i(x^*), \mu_i^* \neq 0$$


pro $\forall i = 1, \dots, m$

Tato podm. se nazývá podmínkou komplementarity.

$$\text{a), c)} \Rightarrow \nabla f(x^*) + \mu^* g(x^*) = 0$$

Označím $J = \{i \in \{1, \dots, m\} \mid g_i(x^*) = 0\}$ Tato množina je množina indexů aktuálních podmínek na x^* .

$$\text{Potom a), c)} \Rightarrow \nabla f(x^*) = - \sum_{i \in J} \mu_i^* \nabla g_i(x^*) \quad (\mu_i^* = 0 \quad i \notin J)$$



Věta: Ježliž je f a $g_i, i=1, \dots, m$ jenou konvexní a spojité diferencovatelné na konvexním m. M. A ježliž (x^*, u^*) je K-T stacionární bod, potom x^* je opt. řešení užlohy (1).

$$\text{Důkaz: } f(x) - f(x^*) \geq \nabla f(x^*)^T (x - x^*) \quad \forall x \in M \quad (\forall x \in N)$$

$$\text{Platí podle věty } g_i(x) - g_i(x^*) \geq \nabla g_i(x^*)^T (x - x^*) \quad \forall x \in M \quad \forall i = 1, \dots, m$$

$$x^* \in M, \nabla f(x^*) = -u^* \nabla g(x^*)$$

$$\Rightarrow f(x) - f(x^*) \geq -u^* \nabla g(x^*) (x - x^*) \geq -u^* \nabla (g(x) - g(x^*)) = \\ = -u^* \nabla g(x) + u^* \nabla g(x^*) = -u^* \nabla g(x) \geq 0 \quad \forall x \in M$$

$$f(x) \geq f(x^*), \forall x \in M \Rightarrow x^* \text{ je opt. řeš. (1)}$$

oen: Převádíme tedy řešení optimalizační užlohy na řešení soustavy rovnic a nerovností (tj. K-T podmínky). Speciálně ve kvadratickém programování derivace \Rightarrow lineární!

Dualita

Lagrangeova dualita

Definice: K užloze (1) def. dualní užlohu

$$(2) \max_K \phi(x, u); K = \{x \in N, u \geq 0 \mid \nabla_x \phi(x, u) = 0\}$$

Seba řešení o dualitě: Nechť f a g_i jenou konvexní, spojité diferencovatelné na konvexním m. N.

Potom platí $\inf_M f \geq \sup_K \phi(x, u)$.

Dk: Je-li $M = \emptyset$ nebo $K = \emptyset \Rightarrow$ řešení již někde platí!

Nechť $M \neq \emptyset, x^* \in M$ lib; $K \neq \emptyset, (x^*, u^*) \in K$ lib.

$$\text{Předp. } f(x^*) - f(x^2) \geq \nabla f(x^2)^T (x^* - x^2)$$

pro lin.-prog.
množinovou dualitu

$$g_i(x^1) - g_i(x^2) \geq \nabla g_i(x^2)^T (x^1 - x^2) \quad \forall i \quad / \cdot \mu_i^2 \quad (31)$$

$$x^1 \in M \rightarrow x^1 \in N, g_1(x^1) \leq \sigma \quad / \cdot \mu^2$$

$$(x^2, \mu^2) \in K \Rightarrow (\cancel{x^2 \in N}) \quad x^2 \in N, \mu^2 \geq \sigma$$

$$\nabla f(x^2) = \mu^2 \nabla g(x^2) = \sigma \quad / \cdot (x^1 - x^2)$$

$$\underline{\Rightarrow f(x^1) - f(x^2) \geq -\mu^2 \nabla g(x^2)(x^1 - x^2)} \geq -\mu^2 (g(x^1) - g(x^2)) =$$

$$= -\underbrace{\mu^2 \cdot g(x^1)}_{\leq 0} + \mu^2 \cdot g(x^2) \geq \underbrace{\mu^2 g(x^2)}$$

$$f(x^1) \geq f(x^2) + \mu^2 g(x^2) = \phi(x^2, \mu^2) \quad \square$$

• Platí i silná věta o dualitě.

Metody řešení úloh ne-lineárního programování

I. metody pro nalezení 'volného' extrému ($\min_{\mathbb{R}^n} f(x)$)

Newtonovské
gradiente


Využívají se u penalizačních a barrierových metod
(kdy převádějí úlohu na vázaný extremum na posloupnost úloh na volný extremum)

II. metody přípustných směrů ('nejčastější')

• najdeme \exists lib $x^* \in M$. (= největší problém - majit výchozí příp. řeš.)

1) hledáme přípustný směr

2) hledáme delší kroky.



• Franka a Wolfa || Zadání & dílčí

• vhodné pro případ, když M je jednoduchá (nejraději konvexní polyeder)
s obecnou funkcí $f(x)$.

III metody sečných matic Kleinmutter

• vhodné pro jednoduchou eliptickou funkci f (lineární) s obecnou M

• najdeme výchozí konvexní polyeder (nebo aspoň konvexní množinu) Z_1
tak, aby $Z_1 \subset M$. Hledáme $\min_{Z_1} f(x)$. Opt. řeš \bar{x}^1 , je-li $\bar{x}^1 \in M$
jmenem hotovi.

Jinak najdeme sečnou maticovou, která oddělí \bar{x}^1 od M

Dostaneme $Z_2 = Z_1 \cap \{x \mid a^T x \leq b\}$ a řeš $\min_{Z_2} f(x)$

Dostaneme $Z_1 \supset Z_2 \supset Z_3 \supset \dots \supset M$.

IV. Metody využívající K-T. p.


• Vhodné pro řešení kvadratického progr.

IV. Spec. metody pro spec. problém

Metoda Franka-Wolfa

$\min f(\mathbf{x}) ; M = \{ \mathbf{x} \in \mathbb{R}^n \mid A\mathbf{x} \leq b, \mathbf{x} \geq 0 \}, A \in \mathbb{R}^{m \times n}, f$ pseudokonvexní na M.

Předp: $M + \phi \Rightarrow \mathbf{x}^T \nabla f(\mathbf{x}^*)$ je nahoře omezena $\overset{\text{na M}}{\text{pro } \mathbf{x}^* \in M}$ (je splneno, když Monotona)



$\mathbf{x}^* \text{ const}$

$$(\mathbf{x} - \mathbf{x}^*)^T \nabla f(\mathbf{x}^*) \sim \min_{\mathbf{x}^T} \mathbf{x}^T \nabla f(\mathbf{x}^*) = \hat{\mathbf{x}}^T \nabla f(\mathbf{x}^*)$$

počer: $\hat{\mathbf{x}}^* - \mathbf{x}^*$

$$\min_{0 \leq \lambda \leq 1} f(\mathbf{x}^* + \lambda(\hat{\mathbf{x}}^* - \mathbf{x}^*))$$

$$\lambda = 1 \rightarrow \mathbf{x}^{n+1} \text{ na hranici M}$$

$$\lambda < 1 \rightarrow \mathbf{x}^{n+1} \text{ je bod obrazu.}$$

- Alg:
- 1) Řeš úlohu LP $\min_M 0$. Potom je $M + \phi$ dosažené $\mathbf{x}' \in M$ my chci. $x=1$
 - 2) máme $\mathbf{x}^* \in M$. Řeš úlohu $\min_M \mathbf{x}^T \nabla f(\mathbf{x}^*)$ SM. Najdeme $\hat{\mathbf{x}}^*$ opt. řeš. $\Rightarrow (\hat{\mathbf{x}}^* - \mathbf{x})^T \nabla f(\mathbf{x}^*) \leq 0, \mathbf{x} \in M$.

IV. F.W: Platí-li $(\hat{\mathbf{x}}^* - \mathbf{x})^T \nabla f(\mathbf{x}^*) = 0$, potom je \mathbf{x}^* opt. řeš. zadání úlohy.

Dl: Protože $\mathbf{x}^* \in M \Rightarrow (\hat{\mathbf{x}}^* - \mathbf{x})^T \nabla f(\mathbf{x}^*) \leq 0$

$$\stackrel{?}{=} (\hat{\mathbf{x}}^* - \mathbf{x})^T \nabla f(\mathbf{x}^*) \leq 0 \Rightarrow \underbrace{(\mathbf{x}^* - \mathbf{x})^T \nabla f(\mathbf{x}^*)}_{\mathbf{x}^* - \hat{\mathbf{x}}^*} + (\hat{\mathbf{x}}^* - \mathbf{x})^T \nabla f(\mathbf{x}^*) \leq 0 \Rightarrow$$

$$= 0$$

$$\Rightarrow (\mathbf{x}^* - \mathbf{x})^T \nabla f(\mathbf{x}^*) \leq 0 \quad \forall \mathbf{x} \in M$$


$$\stackrel{?}{=} \text{pseudokonvexity} \quad f(\mathbf{x}) \leq f(\mathbf{x}^*) \Rightarrow \nabla f(\mathbf{x}^*)^T (\mathbf{x} - \mathbf{x}^*) < 0 \quad \Rightarrow f(\mathbf{x}) \geq f(\mathbf{x}^*), \mathbf{x} \in M$$

(12)

09.05.2008


2-V.F.W: Jestliže platí $(\hat{\mathbf{x}}^* - \mathbf{x}^*)^T \nabla f(\mathbf{x}^*) < 0$ a $(\hat{\mathbf{x}}^* - \mathbf{x}^*)^T \nabla f(\hat{\mathbf{x}}^*) \leq 0$,

potom $\mathbf{x}^{n+1} = \hat{\mathbf{x}}^*$ a $f(\mathbf{x}^{n+1}) < f(\mathbf{x}^*)$.



3.V. FW: jestliže platí $(\hat{x}^r - x^r) \cdot \nabla f(x^r) < 0$ a $(\hat{x}^r - x^r) \cdot \nabla f(\hat{x}^r) > 0$, (32)

pokud položíme $\hat{x}^{r+1} = x^r + \lambda_r (\hat{x}^r - x^r)$, $f(\hat{x}^{r+1}) < f(x^r)$
 kde λ_r je řešením rovnice $(\hat{x}^r - x^r)^T \nabla f(x^r + \lambda (\hat{x}^r - x^r)) = 0$
 $(\equiv \min_{\langle 0,1 \rangle} f(x^r + \lambda (\hat{x}^r - x^r))$



4.V.: $\{x^*\}$ má alespoň 1 kandidující bod x^* , který je opt. řeš.
 zadání užlohy. (když máme V1&V2 → ty zaručují konvexnost)

Vicekriteriální programování (vektorová optimizace)

(1) $\max_M f(\star)$, $M = \{\star \mid g_j(\star) \leq 0\}$, kde $f_i(x)$, $g_j(x)$ ($i=1, \dots, s$)

($j=1, \dots, m$) jsou reálné funkce def. na \mathbb{R}^n .

a) ideální řeš. - $\max_M f_i(x) = f_i(x^*) \quad \forall i$

b) dominantské řeš. - $\exists i_0 \in \{1, \dots, s\}$ tak, že řeší (1) omezení na řešit $\max_M f_{i_0}(x)$.

c) eficiencké řeš.

Def: Překl. $x^* \in M$ nazveme eficiencké řeš. užlohy (1), jestliže

$\nexists x \in M$ tak, aby plnilo ~~$f(x) \leq f(x^*)$~~ $f(x) \geq f(x^*)$.

Množina všech eficienckých řešení označíme E .

Def: Překl. $x^* \in M$ nazveme vlastním eficienckém řešením užlohy (1), jestliže $\forall i \in \{1, \dots, s\}$ a $\forall x \in M$ pro které platí $f_i(x) > f_i(x^*)$

$\exists \beta > 0 \mid \exists k \in \{1, \dots, s\}$ tak, že $f_k(x) < f_k(x^*)$,

$$\frac{f_i(x) - f_i(x^*)}{f_k(x^*) - f_k(x)} \leq \beta$$

d) kompromismu řeš. $f(x) \rightarrow F(x)$ původně málohm' fci

ad c): (přev'e s' na sh. ekvivalent)

Parametrický sh. ekvivalent je:

$$\max_M \lambda^T f(x), \quad \lambda \in \Lambda = \{ \lambda \in \mathbb{R}^n \mid \lambda \geq 0 \}$$

Poz.-li $M_{\text{opt}}(\lambda) = \{ x^* \in M \mid \max_M \lambda^T f(x) = \lambda^T f(x^*) \}$ pro $\lambda \in \Lambda$
potom platí něta:

Věta: $\bigcup_{\lambda \in \Lambda} M_{\text{opt}}(\lambda) \subset \mathcal{E}$.

Dle: Nechť $x^* \in \bigcup_{\lambda \in \Lambda} M_{\text{opt}}(\lambda) \rightarrow \exists \lambda^* \geq 0$ tak, že $x^* \in M_{\text{opt}}(\lambda^*)$
 $\rightarrow \lambda^{*T} f(x) \leq \lambda^{*T} f(x^*), \quad \forall x \in M$

Pro dr. sporému předp., že $x^* \notin \mathcal{E} \rightarrow \exists \bar{x} \in M$ tak, že $f(\bar{x}) > f(x^*)$
 $\xrightarrow{\cdot \lambda^* \geq 0} \lambda^{*T} f(\bar{x}) > \lambda^{*T} f(x^*)$

Poznámka

1) Platí-li, že f_i, g_j jsou lineární, pak jele o lineární
vícenásobná lín' opd.

2) Platí-li, že f_i -konkávní a g_j -konvexní, pak jele o konvexní
vícenásobná lín' opd.

Twzem': Pro lin. vícenásob. prog. platí $\bigcup_{\lambda \in \Lambda} M_{\text{opt}}(\lambda) = \mathcal{E} \subset \mathcal{E}$ je
rovná množině vl. efic. řeš.

Pro konkávní vícenásob. prog. platí $\bigcup_{\lambda \in \Lambda} M_{\text{opt}}(\lambda) \subset \mathcal{E} \subset \bigcup_{\lambda \in \Lambda \setminus \{0\}} M_{\text{opt}}(\lambda)$
 $\lambda > 0 \quad \lambda \geq 0$

1. Alg. dialogue

$\lambda_0, \lambda_1 > 0$ (zvolíme bud' něživ. II. řádu)

$$x^* \in M_{\text{opt}}(\lambda_0) \quad x^*, x_1 \in E$$

Réšíme některý 1-param.

$$x^* \in M_{\text{opt}}(\lambda_1)$$

$$(*) \max (\lambda_0 + \lambda_1 (\lambda_1 - \lambda_0))^\top f(x) \quad \text{pro } \lambda \in (0, 1) \\ x \in M$$

dag zakl., že majdeme řeš. pro $\lambda = 0$. tj. $\max \lambda_0^\top f(x)$ užívající stabilitu

$$\equiv \lambda_0^\top f(x^*) \quad \text{a obor stability } x^* \rightarrow \lambda_1 > 0. \text{ Hodnota } f(x^* + \lambda_1 (\lambda_1 - \lambda_0))$$

zvážu užívatele a rozhodne se:

a) pokračuje me v řeš. (*) pro $\lambda > \lambda_1$.

b) změníme λ_1 a řešíme (*)

c) vrátíme se k předchozímu kroku

d) změníme λ_0, λ_1

w) užívatel je spokojen - konec

2. Alg. dialogue

* nejprve se aplikuje 1. alg. dialogue $f_i(x^*) \quad (i \in K)$

Tef možíme $K \subseteq \{1, \dots, s\}$, kde chce zlepšit hodnoty

a $\mu_i > 0$ o kolik chce alespoň zlepšit tyto hodnoty.

Definujme $M(K, \mu) = \{x \in M \mid f_i(x) \geq f_i(x^*) + \mu_i, i \in K\}$


Ozm. $\tilde{K} = \{1, \dots, s\} \setminus K$.

Réšíme některý

$$\max_{M(K, \mu)} \sum_{i \in K} x_i f_i(x) \quad 1. \text{ alg. dialogue.}$$

2) uživ. je spokojen

B) může změnit K nebo μ_i



(33)

ad d):

1) informace o preferenciích užívatele nedostaneme

• Metoda globálního cílového funkce

$$\max_{x \in M} f_i(x) = f_i^* \geq_0 k_i$$

$$\min_M \left\{ \sum_{i=1}^M \left(\frac{f_i^* - f_i(x)}{f_i^*} \right)^p \right\} \quad p = 1, 2, \infty$$

\Rightarrow kompromisní řešení & díl se dohází, ne je eficientní!

2) informace o preferenciích dosaheme přiřeď načátkem výpočtu

• Metoda funkce užitku

$$\max_M \sum_{i=1}^M w_i f_i(x), \quad w_i > 0, \quad \sum_{i=1}^M w_i = 1$$

∇ nesouměřitelné funkce dělájí problém.

3) informace o preferenciích dosaheme během výpočtu

• $f_1 = f_i$ - porovnávání 2 funkcí

$\nabla f_1 = -\nabla f_i \quad \rightarrow$ převod na funkci užitku
- nebo do k. eficientní

4) informace o p. až po ukončení výpočtu

• zkusme díl a řeš. $\max_M \lambda^T f(x)$

x_1
 x_2
 \vdots

ad d):

(34)

1) informace o preferencích uživatele nedostaneme

- Metoda globální 'cílové' funkce

$$\max_{x \in M} f_i(x) = f_i^* \geq f_i$$

$$\min_M \left\{ \sum_{i=1}^n \left(\frac{f_i^* - f_i(x)}{f_i^*} \right)^p \right\}, \quad p = 1, 2, \dots$$

⇒ kompromisní řešení & da se dohádat, zda je eficientní

2) informace o preferencích dosazeme před násobkem výpočtu

- Metoda funkce mřížky

$$\max_M \sum_{i=1}^n w_i f_i(x), \quad w_i > 0, \quad \sum_{i=1}^n w_i = 1$$

▷ 'resourcenětílné' řešení dělají problém.

3) informace o preferencích dosazeme během výpočtu

- $f_1 = f_i$ - porovnávání 2 funkcí
- $\nabla f_1 = -\nabla f_i \quad \forall i$ → převod na fci mřížky
- nebezpečí dob. eficientní

4) informace o p. až po ukončení výpočtu

- obecně λ a řeš. $\max_M \lambda^T f(x)$

x_1
 x_2
⋮

(13)

16.05.2008

Dynamické programování - diskrétní

Systém - předmět našího zkoumání. Ten zkoušíme v čas. intervalu $[t', t'']$.

Stav - všechny potřebné informace o systému v čas. okamžiku $t \in [t', t'']$.

Změna - li dělení $[t', t'']$ salto dave $t_1 \equiv t' < t^2 < \dots < t^M \equiv t''$, kde $M \geq 1$, posouváním systému v t^i se musí dát vyjádřit uspořádánou m -síťí reálných čísel $x^i \in \mathbb{R}^m$. Možíme všechny přípustné stavů $X \subset \mathbb{R}^{m \times M}$.

Stav systému se může měnit pouze v časových okamžících t^i než vkládá do rozhodnutí - $u^i \in \mathbb{R}^m$ (usp. m-síťí reálných č.). Množství všech možných rozhodnutí označíme $U \subset \mathbb{R}^{m \times M}$.

Změna je dána vztahovou transformací $x^{i+1} = T_i(x^i, u^i) \quad \forall i = 1, \dots, M-1$.

Dělení:

35

- ① máme zadán poč. stav x^1
- ② máme zadán koncový stav x^{N+1}
- ③ máme zadán poč. stav x^1 a tak i koncový stav x^{m+1}
- ④ máme zadánu $X^1 \subset X$ a bereme $x^1 \in X^1$
- ⑤ \dots $X^{N+1} \subset X$ a bereme $x^{N+1} \in X^{N+1}$
- ⑥ nezmáme N a současné množství májí nejménší N , při kterém je úloha řešitelná nebo pro které dostávám nejlepší hodnotu cílové funkce.

ad ①:
$$\frac{x_1^1 u^1}{t^1 = t^N} \quad x^2 \quad u^2 \quad x^3 \quad u^3 \quad x^4 \quad u^4 \quad \dots \quad \frac{u^N x^{N+1}}{t^N = t^1}$$

Def: Říkáme, že v časovém int (t^1, t^N) probíha 'diskretně' rozhodovací deterministický proces, jestliže:

- a) máme dano dělení $(t^1, t^N) : t^1 = t^1, \dots, t^N = t^N, N > 1$
- b) x^1 je daný počáteční stav
- c) stav se může změnit jen v t^i a podle stavové funkce $x^{i+1} = T_i(x^i, u^i) \forall i = 1, \dots, N$ (x^{i+1} závisí pouze na stavu x^i a provedeném rozhodnutí u^i)

Def: Posl u^1, \dots, u^N s vlastností $u^i \in U, x^{i+1} = T_i(x^i, u^i) \in X, i=1, \dots, N, x^1 \in X$, nazýváme původní strategii.

Množina všech původních strategií (přiřazených danému systému a rozh. diskr. det. procesu) označíme $P_N(x^1) = \{(u^1, \dots, u^N) \mid u^i \in U, x^{i+1} = T_i(x^i, u^i) \in X, i=1, \dots, N\}$

Pozn: Dáno $N, x^1 \in X$, ale vždy musíme počítat úlohu pro $x^1 \in X$ a několikačet původních strategií pro x^1 .

Abychom měli úlohu diskr. det. dyn. programu musí cílová funkce, kterou přiřadíme rozhodovacímu procesu splňovat:

$$(1) f_1(x^1, u^1), f_2(x^1, x^2, u^1, u^2), \dots, f_N(x^1, \dots, x^N, u^1, \dots, u^N)$$

(2) markovská vlastnost: $\forall N$

$$f_N(x^1, \dots, x^N, u^1, \dots, u^N) = \phi(f_{N-1}(x^1, \dots, x^{N-1}, u^1, \dots, u^{N-1}), \varphi(x^N, u^N))$$

$$\text{Př: } f_{m+1}(x^1, \dots, x^N, u^1, \dots, u^N) = \sum_{i=1}^N g_i(x^i, u^i)$$

$$\prod_{i=1}^N g_i(x^i, u^i)$$

$$\min_{i=1, \dots, N} \{ g_1(x^1, u^1), \dots, g_N(x^N, u^N) \}$$

17.

et
učí

Def: Ulohou DDDP rozumíme ulohu:

(36)

$$\max f_N(x^1, \dots, x^N, u^1, \dots, u^N)$$

$$\{u^1, \dots, u^N\} \in P_N(x^1)$$

Pozn: Polozíme $f(x^1, \dots, x^N, u^1, \dots, u^N) = \sum_{i=1}^N g_i(x^i, u^i)$

Věta: jsou-li $g_i(x^i, u^i)$ dane reálné funkce $T_i(x^i, u^i)$ dane nábrzem definované pro $\forall i=1, \dots, N^*$, $N^* > 1$, $x^i \in X$, $u^i \in U$ a jistíže pro dany $x^i \in X$ platí $\cancel{x^{i+1}} = T_i(x^i, u^i)$ $\forall i=1, \dots, N$ a označí

$$\max_{P_N(x^1)} \sum_{i=1}^N g_i(x^i, u^i) = F_N(x^1), \quad 1 \leq N \leq N^*$$

$$\max_{P_{N-1}(x^2)} \sum_{i=1}^N g_i(x^i, u^i) = F_{N-1}(x^2), \quad 2 \leq N \leq N^*,$$

$P_{N-1}(x^2)$

$$\text{kde } P_{N-1}(x^2) = \{ (u^1, \dots, u^{N-1}) \mid u^i \in U, x^{i+1} = T_i(x^i, u^i) \in X, i=2 \dots N, x^2 \in X \}$$

potom platí $F_N(x^1) = \max_{\substack{u^1 \in U(x^1) \\ \dots \\ u^N \in U(x^N)}} \{ g_1(x^1, u^1) + F_{N-1}(x^2) \} = \max_{\substack{u^1 \in U(x^1) \\ \dots \\ u^N \in U(x^N)}} \{ g_1(x^1, u^1) + F_{N-1}(T_1(x^1, u^1)) \},$

$$\text{kde } N = 1 \dots N^*, \quad F_0(x) = 0 \quad \forall x \in X, \quad U(x) = \{ u^i \in U \mid x^{i+1} = T_i(x^i, u^i) \in X \}$$

Algoritmus:

1) pro každé $x^N \in X$ počítáme $F_1(x^N) = \max_{u^N \in U(x^N)} g_N(x^N, u^N)$, $U(x^N) = \{ u^N \in U \mid x^{N+1} \in X \}$
 $= g_N(x^N, u^{N*})$

2) pro každé $x^{N-1} \in X$ počítáme $F_2(x^{N-1}) = \max_{u^{N-1} \in U(x^{N-1})} g_{N-1}(x^{N-1}, u^{N-1}) + F_1(x^N, \cancel{u^N}) =$
 $= \max_{u^{N-1} \in U(x^{N-1})} \{ g_{N-1}(x^{N-1}, u^{N-1}) + F_1(T_{N-1}(x^{N-1}, u^{N-1})) \} = g_{N-1}(x^{N-1}, u^{N*}) + F_1(T_{N-1}(x^{N-1}, u^{N*}))$

X	$F_1(x^N)$	u^{N*}	$F_2(x^{N-1})$	u^{N*}
\vdots				
(x_N)				
\vdots				
x^1				

N-1: Pro každé $x^2 \in X$ počítáme $F_{N-1}(x^2) = \max_{u^2 \in U(x^2)} \{ g_2(x^2, u^2) + F_{N-2}(x^3) \}$
 $\frac{1}{T_2(\dots)}$

N: Pro každé $x^1 \in X$ počítáme $F_N(x^1) = \max_{u^1 \in U(x^1)} \{ g_1(x^1, u^1) + F_{N-1}(x^2) \}$

23. 5. 2008

(20)

(37)

KONEČNÉ MATICOVÉ HRY DVOCH HRAČOV S NULOVÝM SÚČETOM

Máme dve hračky:

1. hračka má k dispozícii $i \in \{1, \dots, n\}$ strategie pre danú hru
2. — — — $j \in \{1, \dots, m\}$ — — —

Keď budú hrať N -krát ($N \in \mathbb{N}, N \gg 0$).

Ak zvolí 1. hračka strategiu i a 2. hračka strategiu j potom 1. hračka získa hodnotu a_{ij} , ktorú 2. hračka straci. ($a_{ij} < 0$ pripadá v algoritme)

$$\forall i, j \Rightarrow \text{dosažené } A = (a_{ij})_{ij}$$

Definícia:

Možnosť $\{1, 2\}, i \in \{1, \dots, n\}, j \in \{1, \dots, m\}, A\}$ nazívame konečnú maticovú hru dvoch hračcov s nulovým súčetom.

Ak hračka 1. hračka volá jednu strategiu (hovoríme o čistej stratégii) a hračka 2. hračka je hračka neručujúca. Označme x_i pravdepodobnosť, že 1. hračka použije strategiu i a y_j pravdepodobnosť, že 2. hračka použije strategiu j .

$$\text{Označme } [X] = \{x \in \mathbb{R}^n \mid \mathbf{1}^T x = 1, x \geq 0\}$$

$$[Y] = \{y \in \mathbb{R}^m \mid \mathbf{1}^T y = 1, y \geq 0\}$$

Pravdepodobnosť, že sa stretneš s j -ou stratégou, je $x_i y_j$.

Do N hrach je radek $N \sum_j a_{ij} x_i y_j$ a teda riadok $\sum_i a_{ij} x_i y_j = x^T A y$

Definícia:

Možnosť $\{1, 2\}, [X], [Y], x^T A y\}$ nazívame zmiešaným rozšírením maticovej hry, pričom $x^T A y$ nazívame cenu hry.

Platíme $x^* \in [X]$ a $y^* \in [Y]$, aby $x^T A y^* \leq x^* T A y^* \leq x^* T A y$, $x \in [X], y \in [Y]$.

1. hračka maximizuje $x^T A y$ a 2. hračka ju minimizuje.

Definícia:

Strategie x^* a y^* nazívame optimálnymi stratégiami a $x^* T A y^*$ optimálnou cenou hry.

Veta 1:

Ak sú \bar{x}^*, \bar{y}^* a \tilde{x}, \tilde{y} dve rovne dvojice optimálnych stratégii, potom

$$\bar{x}^*{}^T A \bar{y}^* = \tilde{x}^*{}^T A \tilde{y}.$$

Dôkaz 1:

$$\begin{aligned} \bar{x}, \bar{y} - \text{opt.} \stackrel{\text{def.}}{\Rightarrow} \bar{x}^*{}^T A \bar{y} \leq \tilde{x}^*{}^T A \bar{y} \leq \tilde{x}^*{}^T A \tilde{y} \leq \bar{x}^*{}^T A \tilde{y}^* \leq \bar{x}^*{}^T A \bar{y} \end{aligned}$$

$\nwarrow \uparrow$
 $\bar{x}, \bar{y}^* - \text{opt.}$

Lemma:

Ak je $J = (J_{ij})_{n \times m}$ a $\lambda \geq 1 - \min_{i,j} z_{ij}$, potom $\bar{A} \equiv A + \lambda J \geq 0$.

$$\begin{pmatrix} 1 & \dots & ? \\ \vdots & \ddots & \vdots \\ i & \dots & j \end{pmatrix}$$

Dôkaz:

$$\text{Pre libovolné } \tilde{x}_{ij} = x_{ij} + \lambda \geq \min_{i,j} x_{ij} + \lambda = 1 \Rightarrow \bar{A} \geq 0.$$

Veta 2:

Ak sú \bar{x}^0 a \bar{y}^0 optimálne riešenia siloh LP (prímána, dualna)

$$(P) \min_M \bar{1}^T \bar{x} \quad M = \{x \mid \bar{A}^T x \leq \bar{1}, x \geq 0\}$$

$$(D) \max_N \bar{1}^T \bar{y} \quad N = \{y \mid \bar{A} y \leq \bar{1}, y \geq 0\}$$

Potom $\bar{x}^* = \frac{\bar{x}^0}{\bar{1}^T \bar{x}^0}$, $\bar{y}^* = \frac{\bar{y}^0}{\bar{1}^T \bar{y}^0}$ sú optimálne stratégie

a $\bar{x}^*{}^T \bar{A} \bar{y}^*$ je optimálna cena hry.

Dôkaz:

Pretože $\bar{1}^T \bar{y}$ je nulový vektor

Pretože $\bar{1} \in N \Rightarrow N \neq \emptyset$.

Pretože $\bar{A} \geq 0 \Rightarrow N \neq \emptyset$ obmedzené } $\Rightarrow (D)$ má riešenie \bar{y}^0 .

Z principu duality $\Rightarrow (P)$ má riešenie \bar{x}^0 a platí $\bar{1}^T \bar{x}^0 = \bar{1}^T \bar{y}^0$.

Z definície \bar{x}^* a $\bar{y}^* \Rightarrow \bar{x}^* \in [X], \bar{y}^* \in [Y]$.

Zvolme libovolné $x \in [X] \Rightarrow x \geq 0, \bar{1}^T x = 1$

a libovolné $y \in [Y] \Rightarrow y \geq 0, \bar{1}^T y = 1$

$$\begin{aligned} \text{Pro } y^0 \text{ platí } A y^0 \leq 1 / \star \Rightarrow x^T \bar{A} y^0 \leq 1^T x = 1 \Rightarrow x^T \bar{A} y^* \leq \frac{1}{\pi^T y^0}. & \quad (20) \quad (3P) \\ \text{Pro } x^0 \text{ platí } \bar{A}^T x^0 = x^{0T} \bar{A} \geq 1 / y \Rightarrow x^{0T} \bar{A} y \geq 1^T y = 1 / \frac{1}{\pi^T x^0}. \\ \} \Rightarrow x^{*T} \bar{A} y \geq \frac{1}{\pi^T x^0} = \frac{1}{\pi^T y^0} \geq x^T \bar{A} y^* \quad \forall x \in X, y \in Y \end{aligned}$$

Pro důvod:

$$\begin{aligned} x^{*T} (A + \lambda I) y &\geq x^T (A + \lambda I) y^* \\ x^{*T} A y + \lambda &\geq x^T A y^* + \lambda \quad \forall x, \forall y \end{aligned}$$

Tedy speciálne:

$$\begin{aligned} x^{*T} A y &\geq x^{*T} A y^* \\ x^{*T} A y^* &\geq x^T A y^* \end{aligned} \quad \Rightarrow x^T A y^* \leq x^{*T} A y^* \leq x^{*T} A y \quad \forall x, \forall y \Rightarrow \\ \Rightarrow \text{jedna hodnota.} \end{math>$$

Důsledok:

Vždy existuje optimálna stratégia horizontálnej maticovej hry
dvou hráčov s nulovým skórom.

Theorie hier

- └ antagonistické - niveli majú správne
- └ neantagonistické
- └ kooperativné
- └ nekooperativné